

武汉大学学报(信息科学版)

Geomatics and Information Science of Wuhan University

ISSN 1671-8860,CN 42-1676/TN

《武汉大学学报(信息科学版)》网络首发论文

题目: 利用散斑引导和扩散去噪的主动立体匹配方法
作者: 鲍国淦, 刘希, 邹勤
DOI: 10.13203/j.whugis20250207
收稿日期: 2025-11-02
网络首发日期: 2025-11-10
引用格式: 鲍国淦, 刘希, 邹勤. 利用散斑引导和扩散去噪的主动立体匹配方法[J/OL]. 武汉大学学报(信息科学版). <https://doi.org/10.13203/j.whugis20250207>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.13203/j.whugis20250207

引用格式:

鲍国淦, 刘希, 邹勤. 利用散斑引导和扩散去噪的主动立体匹配方法[J]. 武汉大学学报(信息科学版), 2025, DOI: 10.13203/j.whugis20250207 (BAO Guogan, LIU Xi, ZOU Qin. Active Stereo Matching Method Using Speckle Guidance and Diffusion Denoising [J]. *Geomatics and Information Science of Wuhan University*, 2025, DOI: 10.13203/j.whugis20250207)

利用散斑引导和扩散去噪的主动立体匹配方法

鲍国淦^{1,2} 刘希¹ 邹勤^{1,2}

1 武汉大学计算机学院, 湖北 武汉, 430072

2 武汉大学国家网络安全学院, 湖北 武汉, 430072

摘要: 传统立体匹配通常无法处理弱纹理区域, 而主动立体匹配通过向场景投射结构光, 可有效缓解因纹理缺少而无法匹配的问题。近年来, 基于深度学习的主动立体匹配方法取得了显著进展, 其中利用引导代价体策略最具代表性。但目前的方法仍然面临两大挑战: 1) 用于引导代价体的引导信号通常较为稀疏且分布不均; 2) 构建的代价体中往往包含大量的冗余信息。为此, 本文提出了一种新的主动立体匹配框架 SGDM (Speckle-Guided Diffusion Matching)。该框架引入散斑变权引导机制提高引导信号的利用效率, 并利用扩散过滤器抑制代价体噪声, 提升匹配的准确性。具体地, 针对引导信号稀疏难以利用的问题, SGDM 引入稀疏视差填充模块扩充视差数量, 并利用变权高斯引导模块优化扩展点的匹配代价, 以提升引导信号的覆盖率和可靠性; 针对代价体中信息冗余影响匹配精度的问题, SGDM 通过引入扩散过滤器以递归方式对代价体进行逐步去噪, 提升代价体的精度, 生成高质量的密集视差图。在仿真和真实数据集上进行的实验结果显示, 融合 SGDM 模块后, 各主流立体匹配网络的整体性能均显著提升: 融合 SGDM 后的 ACVNet 模型在 Scene Flow 数据集上的平均端点误差下降约 16%, 在 SimStereo 数据集上的大于 1 像素误差从 16.60% 显著降低至 4.64%; 融合 SGDM 后的 RAFT 模型在 ETH3D 和 Middlebury 等真实数据集上的误差率平均降低约 26%。这些结果充分验证了 SGDM 在提升立体匹配精度和跨域泛化能力方面的有效性和通用性。

关键词: 主动立体匹配; 散斑结构光; 深度估计; 扩散去噪; 扩散模型

Active Stereo Matching Method Using Speckle Guidance and Diffusion Denoising

BAO Guogan^{1,2} LIU Xi¹ ZOU Qin^{1,2}

1 School of Computer Science, Wuhan University, Wuhan 430072, China

2 School of Cyber Science and Engineering, Wuhan University, Wuhan 430072, China

Abstract: Objectives: Depth estimation is a fundamental task in computer vision and 3D reconstruction, with extensive applications in autonomous driving, robotics, and virtual reality. Traditional stereo matching algorithms often fail in weakly textured or reflective regions, leading to inaccurate disparity estimation. Active stereo matching, which projects structured light such as speckle patterns onto the scene, can alleviate these issues by enriching image textures. However, existing active stereo methods that rely on guided cost volumes still suffer from two main limitations: sparse and unevenly distributed guidance signals, and redundant information in the constructed cost volumes. To address these challenges, a novel active stereo matching framework named SGDM (Speckle-Guided Diffusion Matching) is proposed. **Method:** The proposed SGDM framework integrates three key modules to enhance the utilization of sparse guidance and suppress redundant cost-volume information. (1) A lightweight sparse disparity filling module expands the initially sparse disparity map derived from stereo pairs illuminated by speckle structured light, increasing the number and spatial uniformity of effective disparity points. (2) A variable-weight Gaussian guidance module adaptively adjusts the modulation strength

基金项目: 光明实验室开放基金 (GML-KF-24-35)。

第一作者: 鲍国淦, 硕士生, 主要从事计算机视觉与三维重建相关研究。gguanbao@whu.edu.cn

通信作者: 邹勤, 博士, 教授, 研究领域为机器视觉与机器人。qzou@whu.edu.cn

according to the confidence of disparity points, thereby improving the reliability and precision of the guided cost volume. (3) A diffusion filter is employed to iteratively refine the cost volume through a diffusion-based denoising process, effectively suppressing redundant information and noise to yield a cleaner and more distinctive disparity estimation. These components can be seamlessly integrated into existing stereo matching networks without modifying their original architectures. **Results:** Comprehensive experiments were conducted on both synthetic and real-world datasets, including Scene Flow, KITTI, SimStereo, ETH3D, and Middlebury. The results show that the proposed SGDM framework substantially enhances the accuracy and robustness of stereo matching networks. Specifically, when the proposed SGDM is integrated into ACVNet, the average end-point error (EPE) on the Scene Flow dataset decreases by approximately 16%, and the proportion of pixels with disparity errors greater than one pixel on SimStereo is reduced from 16.60% to 4.64%. Furthermore, incorporating SGDM into RAFT leads to an average error reduction of 26% on ETH3D and Middlebury datasets, demonstrating remarkable cross-domain generalization. Visual comparisons further confirm that SGDM effectively improves disparity estimation in weakly textured and occluded regions, yielding sharper and more detailed disparity maps. **Conclusion:** The proposed SGDM framework effectively addresses two critical limitations in active stereo matching: sparse and uneven guidance signals, and redundant information within the cost volume. By integrating speckle-guided semi-dense disparity priors, a variable-weight Gaussian guidance mechanism, and a diffusion-based denoising filter, SGDM achieves highly accurate, noise-resilient, and generalizable depth estimation. Experimental evaluations across multiple datasets verify that SGDM consistently enhances both matching precision and cross-domain robustness when embedded into mainstream stereo matching networks. In addition to its algorithmic contributions, SGDM offers a scalable and flexible design that can be readily incorporated into various 3D perception systems. Overall, the proposed framework provides a unified and effective solution for advancing active stereo matching, paving the way for broader applications in autonomous driving, robotic perception, and precision 3D reconstruction.

Key words: active stereo matching; speckle structured light; depth estimation; diffusion denoising; diffusion model

深度估计是三维建模和计算机视觉中的关键任务，广泛应用于自动驾驶、机器人导航和虚拟现实等场景^[1-3]。双目立体匹配作为主要实现方式之一，通过立体图像对的二维数据信息提取并恢复对应物体的深度信息^[4]。Scharstein 等^[5]在 2002 年将传统算法划分为局部方法和全局方法，局部方法在弱纹理区域性能较差，而全局方法的复杂度更高。Hirschmuller^[6]的半全局匹配通过将局部匹配与全局优化结合，实现了更好的视差估计。近年来，深度学习推动了立体匹配的快速发展，一系列基于深度学习的立体匹配算法相继被提出^[7]。基于聚合的网络如 GCNet^[8]、PSMNet^[9]、GwcNet^[10]、GANet^[11]和 ACVNet^[12]具有计算效率高的优点；基于迭代的方法如 RAFT^[13]、IGEV^[14]则表现出更强的泛化能力和鲁棒性。尽管基于深度学习的立体匹配方法已取得显著进展，但在弱纹理区域的视差估计仍面临挑战^[15]。

主动立体匹配通常向场景投射散斑结构光等随机纹理图案，为弱纹理区域引入额外的纹理细节，从而显著提升匹配性能。现有主动立体匹配方法主要可分为两类：一类是通过向物体表面投射散斑或条纹等图案增强图像纹理，将增强后的图像直接输入网络以提升匹配精度；另一类则引入深度图或 LiDAR 等引导信号，用于构建或优化代价体，从而提高视差估计的准确性。近年来，基于引导代价体的主动立体匹配方法取得了显著进展。Poggi 等^[16]首次提出代价体引导技术，旨在利用外部引导信号来引导代价体的构建，从而提升模型的性能。Huang 等^[17]提出了稀疏信号超密度方法，通过扩展稀疏信号以最大化其利用效率。Zhang 等^[18]则通过主动视差采样策略，有效缓解了弱纹理区域的欠采样问题，提升了匹配的精度。




图 1 融合 SGDM 的主动立体匹配流程图
Fig. 1 Pipeline of Active Stereo Matching with SGDM

和效率。Xu 等^[19]将 GSM (Guided Stereo Matching)^[16]应用于主动双目系统，借助单目结构光系统估计的深度信息对代价体进行引导。

尽管基于引导代价体的主动立体匹配方法在提升弱纹理区域的匹配能力方面取得了显著成效，但其整体性能仍受到两个关键问题的限制。其一，用于引导代价体的引导信号通常较为稀疏且分布不均，难以为模型提供全面而可靠的引导信息；其二，所构建的代价体中往往包含大量冗余信息，不仅增加了计算开销，还干扰了模型的有效训练，限制了模型整体性能的进一步提升。因此，提升该类方法性能的关键在于：一方面提高引导信号的密度与分布均匀性，另一方面有效去除代价体中的冗余信息，以增强模型的泛化能力与匹配精度。

近年来，扩散模型因其在图像生成与去噪任务中的强大能力，被逐渐引入立体匹配领域。Shao 等^[20]首次将扩散模型应用于视差图生成任务，通过条件扩散机制从噪声中恢复结构清晰、细节丰富的视差图。Li 等^[21]和 Xu 等^[22]分别将扩散模型引入立体匹配任务，通过结合立体几何约束与时序引导机制，实现了更高的时序一致性和跨场景泛化能力。Zheng 等^[23]则将扩散模型扩展至代价体空间，利用代价体作为先验，引导模型从粗匹配逐步生成高精度视差图。扩散模型在立体匹配任务中展现了巨大潜力，然而，目前的扩散模型方法在主动立体匹配中仍存在遮挡处理能力不足、结构边界模糊等问题，限制了其在真实场景下的精度。

基于以上分析，本文提出一种新的主动立体匹配框架 SGDM (Speckle-Guided Diffusion Matching)，旨在解决引导信号稀疏和代价体冗余的问题。针对引导信号稀疏问题，SGDM 通过稀疏视差填充模块扩展有效视差点数量与分布范围，并引入变权高斯引导模块提升填充视差值的可靠性与准确性，显著提高引导信号的利用效率；针对代价体冗余问题，SGDM 引入扩散过滤器对代价体进行递归细化，逐步去除噪声干扰与冗余信息，生成结构清晰、细节丰富的高质量视差图。




图2 轻量级稀疏视差填充模块
Fig. 2 Lightweight Sparse Disparity Filling Module

1 融合 SGDM 的主动立体匹配方法

SGDM 通过稀疏匹配算法从带有散斑图案的左右视图中获取稀疏视差先验，并据此引导代价体的构建，同时结合扩散去噪机制进行优化，从而显著提升模型的整体匹配性能和视差估计精度。图 1 展示了融合 SGDM 的主动立体匹配方法的整体流程。首先，利用 SuperGlue^[24]方法从投射散斑图案的左右视图 I_L 和 I_R 中获取稀疏视差图 D ，其稀疏视差覆盖率约为图像分辨率的 1%，匹配精度在 80% 以上。随后，利用稀疏视差填充模块生成半密集视差图 D_f ，稀疏程度提升至 5% 以上，显著增加有效视差点点的数量并扩大其覆盖范围。接着，提取左右图像的特征，并结合半密集视差图 D_f 通过变权高斯引导模块动态调整引导权重，提升填充视差点的可靠性，并据此构建初始代价体 V_0 。同时，左右图像输入到原始立体匹配算法（本文采用 RAFT 方法），生成初始视差图 P 。该视差图经过离散化处理得到初始扩散过滤器 FV_{init} ，并通过迭代去噪生成期望的扩散过滤器 FV_t 。随后，使用 FV_t 对代价体 V_0 进行细化，有效削弱冗余信息带来的干扰，提升代价体的表达质量和视差估计的准确性。最后，对优化后的代价体 V_t 进行代价聚合，生成最终的视差估计结果 D_f' 。

1.1 轻量级稀疏视差填充模块

文献[25-29]表明，从单目图像与稀疏 LiDAR 点恢复高质量深度具有强大的潜力。文献[17,30]进一步指出，扩展稀疏深度信息能够显著增强其在立体匹配中的引导作用。受此启发，本文提出了一种轻量级稀疏视差填充模块，用于高效补全获取的稀疏视差图，从而提升整体匹配性能。

图 2 展示了轻量级稀疏视差填充模块的整体流程。该模块的输入包括左图 I_L 、右图 I_R 以及稀疏视差图 D ，其中 $D(x, y)$ 表示像素位置 (x, y) 处的视差值， $x \in [0, W-1]$ ， $y \in [0, H-1]$ ， W 和 H 分别为图像的宽度和高度。首先，从稀疏视差图 D 中提取所有满足 $D(x, y) > 0$ 的像素点，并将其视为可靠视差点。对于每一个可靠点 (x, y) ，在其领域窗口 $[x-B, x+B]$ 和 $[y-B, y+B]$ 范围内执行视差填充操作，其中 B 为窗口大小，与稀疏视差图的稀疏程度相关。初始稀疏视差点约占总像素的 1%，当稀疏视差图的稀疏程度达到 5%，且匹配精度保持在 70% 以上时，便能够为后续的代价体构建提供较优的视差先验，因此本文设定 B 为 3。假设当前可靠点的视差为 d ，则对其领域内的每个像素点 (x', y') ，假设其视差值位于区间 $[d-r, d+r]$ 之间。其中参数 r 由场景特性决定，如果场景较为平滑，相邻像素的视差值差异较小， r 可设定得较小；若场景结构复杂，视差变化较大，则需要相应增大 r ，本文设定 r 为 5。在该假设下，遍历该视差范围，并计算左右图像中对应像素块之间的相似度。在相




图 3 变权高斯引导模块

Fig. 3 Variable-Weight Gaussian Guidance Module

似度低于阈值 t 的前提下, 选取相似度最高的候选视差值作为填充值。其中, 较小的 t 表示对像素块相似度要求更高, 从而保证填充值更准确; 较大的 t 则放宽匹配要求, 但可能降低填充精度, 本文设定 t 为 3。通过对每个可靠点执行上述过程, 最终生成半密集视差图 D_f 。

1.2 变权高斯引导模块

文献[16]利用外部深度信息对构建的代价体进行高斯调制, 以引导立体匹配过程。然而, 该方法默认引导信号在空间上均匀分布, 未充分考虑实际场景中稀疏信号分布不均的情况。尽管前文提出的轻量级稀疏视差填充模块在一定程度上缓解了该问题, 但在将原始稀疏点扩展至其邻域的过程中, 填充视差点的可靠性可能发生变化。为此, 本文设计了一种变权高斯引导模块, 可动态调整引导权重, 从而提升填充视差点的可靠性并增强整体匹配精度。

与 GSM 方法类似, 本文同样采用高斯分布对代价体进行调制。针对填充前后视差点在可靠性上的差异, 为不同类型的视差点设计了不同的权重策略。具体而言, 原始稀疏视差点因具有较高的置信度, 被赋予更大的权重; 而扩展的稀疏视差点可靠性相对较低, 因此其权重相应减小。图 3 展示了该模块的具体处理过程。其中, 图 3 的箭头表示单个像素的情况。蓝色箭头由白色方块引出, 表示该像素在未进行引导时的视差相似度分布; 上方红色箭头由颜色较深的方块引出, 表示该像素在利用原始视差值引导后得到的视差相似度分布; 下方红色箭头由颜色较浅的方块引出, 表示该像素在利用填充后的视差值引导后得到的视差相似度分布。在引导前, 代价体 (由蓝色曲线表示) 的分布是相同的。随后, 原始可靠视差点与扩展视差点通过不同高斯函数 (由黑色曲线表示) 进行调制, 最终调制成不同的代价体 (由红色曲线表示)。最终, 调制函数设计如下:

$$G = V[(1 - v_{ij} - w_{ij}) + v_{ij} \cdot k_1 \cdot e^{-\frac{(d - p_{ij})^2}{2c_1^2}} + w_{ij} \cdot k_2 \cdot e^{-\frac{(d - q_{ij})^2}{2c_2^2}}] \quad (1)$$

其中, V 表示初始代价体, G 表示调制后的代价体。 v_{ij} 为原始稀疏视差点的掩码, p_{ij} 为原始稀疏视差值; w_{ij} 为扩展视差点的掩码, q_{ij} 为扩展视差值。 k 控制高斯分布的最大幅度, c 决定高斯分布的宽度。通过赋予 k 和 c 不同的权重, 可以对原始稀疏视差点和扩展视差点进行不同程度的调制。根据视差点的可靠性, 应采用 $k_1 > k_2$ 和 $c_1 < c_2$ 的参数设置进行调制。

对于 v_{ij} 和 w_{ij} 的值, 共有以下三种情况:

- 1) $v_{ij} = 0, w_{ij} = 0$: 表示当前位置无任何引导信息, 对应代价体保持不变;

- 2) $v_{ij}=1, w_{ij}=0$: 表示当前位置由原始稀疏视差点引导, 采用较强调制;
- 3) $v_{ij}=0, w_{ij}=1$: 表示当前位置由扩展视差点引导, 采用较弱调制。




图4 扩散过滤器的前向过程
Fig. 4 The Forward Process of Diffusion Filter

1.3 扩散过滤器

近年来, 基于代价体的立体匹配方法在配对图像中丰富几何信息的加持下取得了显著进展。然而, 代价体中大量冗余信息犹如噪声, 干扰了模型的有效训练并限制了性能的进一步提升。为构建更精确的代价体, 本文引入扩散模型作为代价体的过滤器, 以递归方式去除其中的冗余信息。具体而言, 本文将信息过滤过程建模为一个去噪任务, 通过扩散模型对代价体进行递归去噪, 逐步抑制无效或干扰信息, 从而提升立体匹配的准确性和鲁棒性。

在前向过程中, 将扩散目标从图像转换为注意力扩散过滤器, 具体过程如图4所示。

首先对大小为 $H \times W$ 的真值视差图进行降采样, 降采样后的视差图大小为 $H/4 \times W/4$, 并将每个像素离散化为大小为 $D/4 \times H/4 \times W/4$ 的两个最接近的整数, 这就是扩散过滤器的初始值, 称为 FV_0 。该过程可计算为:

$$FV_0(D/4, x, y) = \text{Discretize}(d_{gt}(x, y)) \quad (2)$$

其中 d_{gt} 是真值视差值, D 是最大视差值, 在训练中设为 192。为了满足 DDPM^[31] 中提到的输入要求, 将扩散过滤器 FV_0 的值从 $(0, 1)$ 重新缩放为 $(-1, 1)$ 。这是前向过程的开始, 然后通过以下方式添加高斯噪声:

$$FV_t = \sqrt{\alpha_t} FV_0 + \sqrt{1 - \alpha_t} \varepsilon \quad (3)$$

其中, α_t 是噪声系数, $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$, ε 表示添加噪声, t 代表时间步长。最后通过扩散过滤器过滤冗余信息。随机抽取一个时间步长 t , 在 $1 \times D/4 \times H/4 \times W/4$ 的 FV_t 中加入 $1 \times D/4$ 的时间嵌入来感知不同的时间步长。然后, 在通道维度 C 上与大小为 $C \times D/4 \times H/4 \times W/4$ 的初始代价体进行逐元素乘法, 公式如下:

$$V_1 = V_0 \odot (FV_t + \text{MLP}(t)) \quad (4)$$

其中, $\odot$ 是逐元素乘积, V_1 表示过滤后的代价体, V_0 表示初始代价体, t 是所选时间步长, MLP 是用于捕获时间序列信息的全连接层。

在逆向过程中, 标准高斯噪声逐步转化为期望的扩散过滤器, 该过程逐步去除代价体中的冗余信息, 具体过程如图5所示。

首先将标准高斯噪声设置为 FV_T , 并将 FV_T 根据公式(4)乘以初始代价体, 预测出视差图 Pred_T 。将 Pred_T 进行离散化转换为概率体积, 其可以被视为与 FV_0 的粗略接近, 将其命名为 FV_0^c 。然后, 通过公式(5)、公式(6)计算前向过程中的附加噪声:

$$FV_0^c(D/4, x, y) = \text{Discretize}(\text{Pred}_T(x, y)) \quad (5)$$

$$\varepsilon = \frac{1}{\sqrt{1-\alpha_T}} (FV_T - \sqrt{\alpha_T} FV_0^c) \quad (6)$$

获得噪声 ε 和 FV_0^c 后, 进一步使用 DDIM^[32] 采样算法恢复 FV_{T-1} , 这就是图 5 的去噪过程。其公式为:

$$FV_{T-1} = \sqrt{\alpha_{T-1}} FV_0^c + \sqrt{1-\alpha_{T-1}-\sigma^2} \varepsilon + \sigma \varepsilon^* \quad (7)$$

其中, $\sigma = \eta \sqrt{(1-\frac{\alpha_T}{\alpha_{T-1}}) \cdot \frac{1-\alpha_{T-1}}{1-\alpha_T}}$, η 是 DDIM 采样系数, 而 ε^* 是高斯噪声。 FV_{T-1} 将对初始代价体进行过滤, 并遵循上述流程, 扩散过滤器将迭代地接近 FV_0 并过滤掉初始代价体中的冗余信息。




图 5 扩散过滤器的逆向过程
Fig. 5 The Reverse Process of Diffusion Filter

2 实验结果与分析

为了全面评估融合 SGDM 的主动立体匹配方法在性能与泛化能力方面的表现, 本文设计了四类实验。第 1 类是将 SGDM 模块集成到不同主流立体匹配网络中, 测试其不同网络结构下的适用性和性能提升效果。第 2 类是在三套主流数据集 (Scene Flow^[33]、KITTI2012^[34]和 KITTI2015^[35]) 上测试六种常见的深度学习立体匹配方法的性能, 并与融合 SGDM 的 ACVNet 方法进行对比, 验证 SGDM 在不同数据场景下的有效性。第 3 类是在 SimStereo^[36]数据集上进行消融实验, 分别评估 SGDM 框架中各个模块对整体性能的贡献。第 4 类是选取 ETH3D^[37]和 Middlebury^[38]两个真实数据集以及 RealSense 采集的图像对, 在未进行微调的条件下, 直接将融合 SGDM 的 RAFT 网络的预训练模型应用于测试, 以评估其在跨数据集、跨域场景下的泛化能力。

2.1 数据集

Scene Flow 是一个大规模的合成立体数据集, 由三个子集构成: Driving、FlyingThings3D 和 Monkaa。该数据集共包含 35454 对训练图像和 4370 对测试图像, 图像分辨率为 960×540, 提供了密集的视差图作为真值。该数据集采用端点误差 (End-Point Error, EPE) 以及视差误差大于 1、2 和 3 个像素的百分比作为评估指标。

KITTI 数据集采集自真实世界的自动驾驶场景。其中, KITTI2012 包含 194 对训练图像和 195 对测试图像, KITTI2015 包含 200 对训练图像和 200 对测试图像, 均提供高质量的真值视差图。考虑到

两个数据集的规模相对较小，先在 Scene Flow 数据集上对模型进行预训练，然后在 KITTI 数据集上进行微调。KITTI2012 使用端点误差（EPE）和视差误差大于 2 和 3 个像素的百分比作为评估指标，KITTI2015 则分别对背景（bg）、前景（fg）以及所有像素（all）的视差离群值百分比 D1 进行评估。

SimStereo 是一个主动-被动融合的合成立体数据集，包含 412 对训练图像和 103 对测试图像，图像分辨率为 640×480 。该数据集提供稠密的视差真值，适用于评估主动立体匹配网络的性能。该数据集采用平均误差（Avg Error）以及视差误差大于 1、2 和 3 个像素的百分比作为评估指标。

ETH3D 数据集包含 27 对来自室内和室外场景的灰度立体图像对，视差范围为 0–64。Middlebury 是一个真实世界采集的立体数据集，涵盖多种照明条件，共包含 23 对图像。由于这两

表 1 SGDM 在 Scene Flow 数据集上的适用性实验

Table 1 The Adaptivity Experiment of SGDM on Scene Flow Dataset

模型	端点误差/像素	大于 1 个像素误差/%
PCWNet	0.84	7.98
PCWNet-GD	0.64	6.50
RAFT	0.72	7.30
RAFT-GD	0.55	6.02
ACVNet	0.48	5.04
ACVNet-GD	0.47	4.24

个数据集规模较小，无法支撑模型训练，因此我们采用零样本泛化方式进行测试。评估指标分别为视差误差大于 1 和 2 个像素的百分比。

2.2 实现细节

本文基于 PyTorch 框架，利用现有立体匹配网络的预训练模型实现所提出的方法。在训练阶段，选用 Scene Flow 数据集的子集 FlyingThings3D finalpass 作为训练数据，训练图像被裁剪为 512×256 。训练过程中，最大视差值设置为 192，采用 AdamW 优化器，初始学习率为 0.001，并通过 lreprochs 参数控制学习率衰减策略，即每训练 20 个 epoch 后进行学习率衰减，缩放因子为 0.5，总共训练 200 个 epoch。在变权高斯引导模块中，参考 GSM 方法设置参数 k_1 为 10， c_1 为 1；在扩散过滤器模块中，前向扩散过程的时间步长设为 1000，逆向过程采用 DDIM 采样策略以提升推理效率。为评估所提方法的有效性，在不同数据集上分别结合不同的基准网络进行实验：以 ACVNet 为基础在 Scene Flow、KITTI 和 SimStereo 数据集上进行测试，以 RAFT 为基础在 ETH3D 和 Middlebury 数据集上进行评估。此外，为在非主动立体匹配数据集上进行测试，本文采用虚拟图案投影（Virtual Pattern Projection, VPP）^[39] 方法对图像进行散斑模式模拟处理。

2.3 适用性实验

提出的 SGDM 是即插即用的，适用于所有基于代价体的立体匹配网络。在表 1 中，我们展示了将 SGDM 融合到 PCWNet、RAFT 和 ACVNet 中的结果，融合后的模型分别命名为 PCWNet-GD、RAFT-GD 和 ACVNet-GD。实验结果表明，融合 SGDM 模块后的立体匹配网络在性能上均有所提升，能够有效增强

现有模型的视差估计能力。

2.4 基准评估

将 ACVNet-GD 与 PSMNet、GwcNet、RAFT、PCWNet、ACVNet 和 IGEV 等主流立体匹配方法在 Scene Flow 数据集上进行性能对比，表 2 展示了各方法在多个评估指标下的测试结果。实验结果表明，ACVNet-GD 在各项指标上均实现了显著的性能提升，尤其在大于 1 像素误差占比方面表现尤为突出。具体来看，ACVNet-GD 的大于 1 像素误差占比仅为 4.24%，显著优于 RAFT 的 7.30% 和 PCWNet 的 7.98%。该结果充分说明，SGDM 能够有效增强模型对稀疏引导信息的利用能力，提升代价体聚合的准确性，从而显著提高立体匹配的整体精度，验证了 SGDM 的有效性。图 6 展示了 ACVNet-GD 与 ACVNet 之间的对比。通过观察图中的边界和细节处理，可以明显看出 ACVNet-GD 在预测质量上优于 ACVNet。特别是在一些特定的边界区域，ACVNet-GD 的预测结果与真实值非常接近。这表明，通过引入 SGDM，ACVNet 在处理复杂场景时能够更准确地捕捉到物体的边缘和细节，从而显著提升预测的准确性。

ACVNet-GD 在 KITTI 数据集上的实验结果也显示出卓越的性能，在 KITTI 2012 和 KITTI 2015 数据集的各项误差指标上均有所提升，如表 3 所示，其中 2-noc 表示非遮挡区域大于 2 个像素误差，2-all 表示全部区域大于 2 个像素误差，3-noc 与 3-all 同理；EPE(noc)和 EPE(all)分别表示非遮挡区域与全部区域的端点误差；D1-bg、D1-fg 和 D1-all 分别表示背景区域、前景区域以及全部区域的离群值误差率。

表 2 ACVNet-GD 在 Scene Flow 数据集上的测试结果
Table 2 Test Results of ACVNet-GD on Scene Flow Dataset

模型	端点误差/像素	离群值误差率/%	大于 1 个像素误差/%	大于 2 个像素误差/%	大于 3 个像素误差/%
PSMNet	1.09	4.20	11.11	6.07	4.14
GwcNet	0.77	2.71	8.03	4.47	3.30
RAFT	0.72	3.42	7.30	4.66	3.55
PCWNet	0.84	2.80	7.98	4.46	3.35
ACVNet	0.48	1.59	5.04	2.74	2.01
IGEV	0.47	2.47	5.38	3.41	2.60
ACVNet-GD	0.47	1.55	4.24	2.41	1.86




图 6 ACVNet-GD 与 ACVNet 的可视化比较
Fig. 6 The Visualization of ACVNet-GD Compared with ACVNet

图 7 进一步通过可视化误差图展示了 SGDM 的优势，其中场景一、场景二的端点误差均为 0.2，场景三、场景四的离群值误差率分别为 0.42 和 0.67。(c)列蓝色区域表示估计准确的部分，红色区域表示误差较大的部分。ACVNet-GD 的误差图显示出较少的红色区域，这意味着其在处理复杂场景时具有更高的准确性。总体而言，SGDM 能够提供更精确的视差估计和更好的整体性能。

表 3 ACVNet-GD 在 KITTI 数据集上的测试结果

Table 3 Test Results of ACVNet-GD on KITTI Datasets									
模型	KITTI2012 数据集						KITTI2015 数据集		
	2-noc	2-all	3-noc	3-all	EPE(noc)	EPE(all)	D1-bg	D1-fg	D1-all
PSMNet	2.44	3.01	1.49	1.89	0.5	0.6	1.86	4.62	2.32
GwcNet	2.16	2.71	1.32	1.70	0.5	0.5	1.74	3.93	2.11
RAFT	1.92	2.42	1.30	1.66	0.4	0.5	1.58	3.05	1.82
PCWNet	1.69	2.18	1.04	1.37	0.4	0.5	1.37	3.16	1.67
ACVNet	1.83	2.35	1.13	1.47	0.4	0.5	1.37	3.07	1.65
IGEV	1.71	2.17	1.12	1.44	0.4	0.4	1.38	2.67	1.59
ACVNet-GD	1.62	2.01	1.04	1.31	0.4	0.5	1.31	2.51	1.47







场景一			
场景二			
场景三			
场景四			
	(a) 参考图像	(b) ACVNet-GD	(c) Error Map

图 7 ACVNet-GD 的可视化结果及误差
Fig. 7 The Visualization Results and Errors of ACVNet-GD

2.5 消融实验

在 SimStereo 数据集上，基于 ACVNet 框架进行了一系列消融实验，实验结果如表 4 所示。其中，ACVNet-S-G 表示使用了稀疏视差图作为引导的 ACVNet 方法；ACVNet-F-G 表示使用了填充后的半密集视差图作为引导的 ACVNet 方法，当 $k_2 = 10, c_2 = 1$ 时，并未采用变权引导机制；而 ACVNet-F-GD 则代表融合了完整 SGDM 的 ACVNet 方法，即使用了扩散过滤器。

从表 4 的第一行和第二行的数据可以看出，ACVNet 在引入稀疏视差图作为引导后，大于 1 像素误差由 16.60%下降至 11.43%。进一步比较第二行和第三行可知，虽然填充后的视差图具有更高的密度，但由于未对不同视差点的权重进行区分处理，其准确性受到了一定影响。为此，提出了变权高斯

引导模块，通过对原始视差点与扩展视差点赋予不同的权重，有效提升了模型对视差引导信息的利用能力。在以 1 为间隔的多组参数实验中（表 4 仅列出部分结果），当 $k_2=1, c_2=10$ 时，模型的性能最优，大于 1 像素误差占比降低至 6.46%，模型性能显著提升。对比 ACVNet-F-G、ACVNet-S-G 与 ACVNet 的实验结果，可以充分验证稀疏视差填充模块与变权高斯引导模块能够有效提升视差估计的准确性。

表 4 融合 SGDM 的 ACVNet 在 SimStereo 数据集上的测试结果

Table 4 Test Results of ACVNet with SGDM on SimStereo Dataset

模型	参数配置	平均误差/像素	大于 1 个像素误差/%	大于 2 个像素误差/%	大于 3 个像素误差/%
ACVNet	-	0.971	16.60	9.42	6.64
ACVNet-S-G	-	0.686	11.43	5.97	3.96
ACVNet-F-G	$k_2=10, c_2=1$	0.708	11.95	6.25	4.14
	$k_2=7, c_2=3$	0.454	7.04	3.49	2.29
	$k_2=5, c_2=5$	0.448	6.72	3.30	2.18
	$k_2=3, c_2=7$	0.467	7.32	3.53	2.28
	$k_2=1, c_2=10$	0.423	6.46	3.24	2.05
ACVNet-F-GD	$k_2=1, c_2=10$	0.293	4.64	2.13	1.32




图 8 融合 SGDM 的 ACVNet 在 SimStereo 数据集上的可视化结果
Fig. 8 The Visualization Results of ACVNet with SGDM on SimStereo Dataset

后，对比表 4 的最后两行可见，在 ACVNet-F-G 的基础上进一步引入扩散过滤器细化代价体后所得 ACVNet-F-GD 方法的大于 1 像素误差进一步降至 4.64%，充分表明扩散过滤器在提升视差估计精度方面的有效性。

在图 8 中，进一步选择了包含显著遮挡和复杂边界的场景，并引入基于扩散模型的深度估计方法 Marigold^[40]作为对比。从（b）到（d）列可以直观体现各模块的逐步改进效果；而（e）列的 Marigold

在遮挡区域易出现错误传播，导致边界估计偏差较大，并在物体结构边界处产生模糊过渡。相比之下，本文方法在引入稀疏视差填充与变权高斯引导模块后，为代价体构建提供了更可靠的先验，再结合扩散过滤器的逐步细化，能够有效抑制遮挡区域的误差扩散，并在结构边界处生成更加清晰、与真实值对齐的预测结果。此外，从图 8 可见，SGDM 在纹理缺失和细节复杂的区域亦表现出更高的预测精度。实验结果不仅证明了 SGDM 在遮挡处理与边界清晰度方面显著优于现有的扩散模型方法，同时验证了 SGDM 中各模块在提升模型整体性能的有效性。


2.6 零样本泛化

由于真实世界数据集规模有限，难以支持深度网络的有效训练，因此从大规模合成数据集泛化到未知真实场景的泛化能力尤为关键。为验证 SGDM 的泛化性能，本文将 RAFT-GD 与 PSMNet、

表 5 RAFT-GD 的泛化实验

Table 5 Generalization Experiments of RAFT-GD			
模型	ETH3D 数据集	Middlebury 数据集	
		全分辨率	半分辨率
PSMNet	23.8	39.5	25.1
GANet	14.1	32.2	20.3
DSMNet	6.2	21.8	13.8
CFNet	5.8	28.2	19.5
RAFT	3.28	18.33	12.59
IGEV	3.59	28.96	9.49
RAFT-GD	2.43	15.07	9.16

GANet、DSMNet^[41]、CFNet^[42]、RAFT 原始模型及 IGEV 等多种主流立体匹配方法进行了系统对比，实验结果如表 5 所示。其中，ETH3D 数据集的评估指标为视差误差大于 1 个像素的百分比，Middlebury 数据集的评估指标为视差误差大于 2 个像素的百分比。从表中可见，RAFT-GD 展现出卓越的跨数据集泛化能力。为更直观地比较性能差异，图 9 展示了 RAFT-GD 与 RAFT 在 ETH3D 和 Middlebury 数据集中多个复杂场景下的可视化结果。从图 9 中可以看出，SGDM 显著提升了细节区域的视差估计质量，尤其在边缘、纹理缺失区域表现出更高的精度与一致性。






图 9 零样本泛化的可视化结果

Fig. 9 The Visualization Result of Zero-Shot Generalization




图 10 RAFT-GD 与 RealSense 的可视化比较

Fig.10 The Visualization of RAFT-GD Compared with RealSense

图 10 进一步展示了 SGDM 在真实世界中由 Intel RealSense D435if 采集的图像对上的泛化效果。实验表明，所提方法在复杂背景、非刚体结构等挑战性场景下仍保持良好的鲁棒性与准确性，充分验证了 SGDM 在提升零样本泛化能力方面的有效性。

3 结 语

本文提出了一种融合散斑变权引导与扩散去噪机制的主动立体匹配新框架 SGDM，旨在解决现有基于引导代价体的主动立体匹配方法中引导信号稀疏且分布不均、代价体冗余等问题。为应对引导信号稀疏且分布不均的问题，SGDM 从投射散斑图案的主动立体图像对中提取稀疏视差图，通过稀疏视差填充模块增强引导信号的密度和分布均衡性，并引入变权高斯引导机制提升视差点点的可靠性，从而为代价体提供更全面、可靠的引导信息。针对代价体冗余的问题，SGDM 进一步引入扩散过滤器对代价体进行递归去噪，有效过滤冗余信息，构建更为精确的代价体，从而生成高质量的密集视差图。

在多个数据集上的广泛实验充分验证了 SGDM 的有效性与通用性。在 Scene Flow 数据集上，ACVNet-GD 将大于 1 像素误差从 5.04%降至 4.24%；在 KITTI2015 数据集上，离群值误差率从 1.65%下降至 1.47%，在真实复杂场景中展现出优异性能；在 SimStereo 数据集上，融合 SGDM 的 ACVNet 方法将大于 1 像素误差从 16.60%显著降低至 4.64%，充分证明了各模块的有效性。此外，在 ETH3D 和 Middlebury 等真实小规模数据集上，SGDM 也表现出强大的跨域泛化能力，RAFT-GD 分别将误差降低至 2.43%和 9.16%。SGDM 框架不仅显著提升了立体匹配模型在弱纹理和复杂结构区域的匹配精度，也具备良好的跨域适应性与实际应用潜力，为构建高精度、鲁棒性的主动立体匹配系统提供了有效路径。

参考文献

- [1] Liu Jin, Ji Shunping. Deep Learning Based Multi-View Dense Matching With Joint Depth and Surface Normal Estimation[J]. Acta Geodaetica et Cartographica Sinica, 2024, 53(12): 2391-2403. (刘瑾, 季顺平. 深度和法线联合估计的深度学习多视密集匹配方法[J]. 测绘学报, 2024, 53(12):

2391-2403.)

- [2] Hu Jianlang, Guo Chi, Luo Yarong. Unsupervised Dense and Continuous Optical Flow Estimation Based on Image and Event Data[J]. Geomatics and Information Science of Wuhan University, 2024. (胡建朗, 郭迟, 罗亚荣. 基于图像和事件的无监督学习稠密连续光流估计[J]. 武汉大学学报 (信息科学版), 2024.)
- [3] Ji Song, Zhang Yongsheng, Yang Zhe, Dai Chenguang. MVLL Match Method for Multi-baseline Stereo Imagery Based on Semi-global Constraint[J]. Geomatics and Information Science of Wuhan University, 2023, 48(1): 155-164. (纪松, 张永生, 杨喆, 戴晨光. 半全局约束下的多基线立体影像 MVLL 匹配方法[J]. 武汉大学学报 (信息科学版), 2023, 48(1): 155-164.)
- [4] Sha Hongjun, Yuan Xiuxiao. State-of-the-Art Binocular Image Dense Matching Method[J]. Geomatics and Information Science of Wuhan University, 2023, 48(11): 1813-1833. (沙洪俊, 袁修孝. 双目影像密集匹配方法的回顾与展望[J]. 武汉大学学报(信息科学版), 2023, 48(11): 1813-1833.)
- [5] Scharstein D, Szeliski R. A Taxonomy and Evaluation of Dense Two-Frame Stereo Correspondence Algorithms[J]. International Journal of Computer Vision, 2002, 47: 7-42.
- [6] Hirschmuller H. Stereo Processing by Semiglobal Matching and Mutual Information[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2007, 30(2): 328-341.
- [7] Ji Shunping, Luo Chong, Liu Jin. A Review of Dense Stereo Image Matching Methods Based on Deep Learning[J]. Geomatics and Information Science of Wuhan University, 2021, 46(2): 193-202. (季顺平, 罗冲, 刘瑾. 基于深度学习的立体影像密集匹配方法综述[J]. 武汉大学学报(信息科学版), 2021, 46(2): 193-202.)
- [8] Kendall A, Martirosyan H, Dasgupta S, et al. End-to-End Learning of Geometry and Context for Deep Stereo Regression[C]. IEEE International Conference on Computer Vision, Venice, Italy, 2017.
- [9] Chang Jiaren, Chen Yongshen. Pyramid Stereo Matching Network[C]. IEEE Conference on Computer Vision and Pattern Recognition, Salt Lake City, America, 2018.
- [10] Guo Xiaoyang, Yang Kai, Yang Wukui, et al. Group-Wise Correlation Stereo Network[C]. IEEE Conference on Computer Vision and Pattern Recognition, Long Beach, America, 2019.
- [11] Zhang F, Prisacariu V, Yang R, et al. GA-Net: Guided Aggregation Net for End-to-End Stereo Matching[C]. IEEE Conference on Computer Vision and Pattern Recognition, Long Beach, America, 2019.
- [12] Xu Gangwei, Cheng Junda, Guo Peng, et al. Attention Concatenation Volume for Accurate and Efficient Stereo Matching[C]. IEEE Conference on Computer Vision and Pattern Recognition, New Orleans, America, 2022.
- [13] Lipson L, Teed Z, Deng J. RAFT-Stereo: Multilevel Recurrent Field Transforms for Stereo Matching[C]. International Conference on 3D Vision, London, UK, 2021.
- [14] Xu Gangwei, Wang Xianqi, Ding Xiaohuan, et al. Iterative Geometry Encoding Volume for Stereo Matching[C]. IEEE Conference on Computer Vision and Pattern Recognition, Vancouver, Canada, 2023.
- [15] Jia Di, Cai Peng, Wu Si, et al. Transformer Network for Stereo Matching of Weak Texture Objects[J]. Journal of Image and Graphics, 2024, 29(08):2413-2425.(贾迪, 蔡鹏, 吴思, 等. 面向弱纹理目标立体匹配的 Transformer 网络[J]. 中国图象图形学报, 2024, 29(08):2413-2425.)
- [16] Poggi M, Pallotti D, Tosi F, et al. Guided Stereo Matching[C]. IEEE Conference on Computer Vision and Pattern Recognition, Long Beach, America, 2019.
- [17] Huang Y K, Liu Y C, Wu T H, et al. S3: Learnable Sparse Signal Superdensity for Guided Depth Estimation[C]. IEEE Conference on Computer

Vision and Pattern Recognition, Online, 2021.

- [18] Zhang Chenghao, Meng Gaofeng, Tian Kun, et al. Active Disparity Sampling for Stereo Matching With Adjoint Network[J]. IEEE Transactions on Image Processing, 2023, 33: 354-365.
- [19] Xu Yuhua, Yang Xiaoli, Yu Yushan, et al. Depth Estimation by Combining Binocular Stereo and Monocular Structured-Light[C]. IEEE Conference on Computer Vision and Pattern Recognition, New Orleans, America, 2022.
- [20] Shao Ruizhi, Zheng Zerong, Zhang Hongwen, et al. DiffuStereo: High Quality Human Reconstruction via Diffusion-Based Stereo Using Sparse Cameras[C]. European Conference on Computer Vision, Tel Aviv, Israel, 2022.
- [21] Li Haodong, Wang Chen, Lei Jiahui, et al. StereoDiff: Stereo-Diffusion Synergy for Video Depth Estimation[J]. arXiv, 2025:2506.20756.
- [22] Xu H, Xu C, Giannarou S. StereoDiffusion: Temporally Consistent Stereo Depth Estimation with Diffusion Models[C]. International Conference on Medical Image Computing and Computer-Assisted Intervention. Marrakesh, Morocco, 2024.
- [23] Zheng Dian, Wu Xiaoming, Liu Zuhao, et al. DiffuVolume: Diffusion Model for Volume based Stereo Matching[J]. International Journal of Computer Vision, 2025: 1-15.
- [24] Sarlin P E, DeTone D, Malisiewicz T, et al. Superglue: Learning Feature Matching with Graph Neural Networks[C]. IEEE Conference on Computer Vision and Pattern Recognition, Seattle, America, 2020.
- [25] Park K, Kim S, Sohn K. High-Precision Depth Estimation with the 3D LiDAR and Stereo Fusion[C]. IEEE International Conference on Robotics and Automation (ICRA), Brisbane, Australia, 2018.
- [26] Choe J, Joo K, Imtiaz T, et al. Volumetric Propagation Network: Stereo-LiDAR Fusion for Long-Range Depth Estimation[J]. IEEE Robotics and Automation Letters, 2021, 6(3): 4672-4679.
- [27] Wu T, Vallet B, Pierrot-Deseilligny M. PSMNet-FusionX3: LiDAR-Guided Deep Learning Stereo Dense Matching on Aerial Images[C]. IEEE Conference on Computer Vision and Pattern Recognition, Vancouver, Canada, 2023.
- [28] Zhang Yongjun, Hong Weichen, Wan Yi. Registration of HRSI and LiDAR Point Clouds Based on Distance Transformation Model[J]. Geomatics and Information Science of Wuhan University, 2023, 48(3): 339-348. (张永军, 洪玮辰, 万一. 利用距离变换模型进行卫星影像与激光点云精配准[J]. 武汉大学学报 (信息科学版), 2023, 48(3): 339-348.)
- [29] Huang Yuanxian, Zhou Jian, Huang Qi, Li Bijun, Wang Lanlan, Zhu Jialin. Camera-LiDAR Fusion for Object Detection, Tracking and Prediction[J]. Geomatics and Information Science of Wuhan University, 2024, 49(6): 945-951. (黄远宪, 周剑, 黄琦, 李必军, 王兰兰, 朱佳琳. 融合相机与激光雷达的目标检测、跟踪与预测[J]. 武汉大学学报 (信息科学版), 2024, 49(6): 945-951.)
- [30] Zhang Yongjun, Zou Siyuan, Liu Xinyi. Sparse Point Cloud Guided Digital Surface Model Generation for Aerial Images[J]. Geomatics and Information Science of Wuhan University, 2023, 48(11): 1854-1862. (张永军, 邹思远, 刘欣怡. 稀疏点云引导的航空影像数字表面模型生成方法[J]. 武汉大学学报(信息科学版), 2023, 48(11): 1854-1862.)
- [31] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models[J]. Advances in Neural Information Processing Systems, 2020, 33: 6840-6851.
- [32] Song J, Meng C, Ermon S. Denoising Diffusion Implicit Models[C]. International Conference on Learning Representations, Online, 2021.
- [33] Mayer N, Ilg E, Hausser P, et al. A Large Dataset to Train Convolutional Networks for Disparity, Optical Flow, and Scene Flow Estimation[C]. IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, America, 2016.
- [34] Geiger A, Lenz P, Urtasun R. Are we ready for Autonomous Driving The KITTI Vision Benchmark Suite[C]. IEEE Conference on Computer Vision and Pattern Recognition, Providence, America, 2012.

- [35] Menze M, Geiger A. Object Scene Flow for Autonomous Vehicles[C]. IEEE Conference on Computer Vision and Pattern Recognition, Boston, America, 2015.
- [36] Jospin L, Antony A, Xu L, et al. Active-Passive SimStereo - Benchmarking the Cross-Generalization Capabilities of Deep Learning-based Stereo Methods[J]. Advances in Neural Information Processing Systems, 2022, 35: 29235-29247.
- [37] Schops T, Schonberger J L, Galliani S, et al. A Multi-View Stereo Benchmark With High-Resolution Images and Multi-Camera Videos[C]. IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, America, 2017.
- [38] Scharstein D, Hirschmüller H, Kitajima Y, et al. High-Resolution Stereo Datasets with Subpixel-Accurate Ground Truth[C]. Pattern Recognition, Münster, Germany, 2014.
- [39] Bartolomei L, Poggi M, Tosi F, et al. Active Stereo Without Pattern Projector[C]. IEEE International Conference on Computer Vision, Paris, France, 2023.
- [40] Ke B, Obukhov A, Huang S, et al. Repurposing Diffusion-Based Image Generators for Monocular Depth Estimation[C]. IEEE Conference on Computer Vision and Pattern Recognition, Seattle, America, 2024.
- [41] Zhang Feihu, Qi Xiaojuan, Yang Ruigang, et al. Domain-Invariant Stereo Matching Networks[C]. European Conference on Computer Vision, Online, 2020.
- [42] Shen Zhelun, Dai Yuchao, Rao Zhibo. CFNet: Cascade and Fused Cost Volume for Robust Stereo Matching[C]. IEEE Conference on Computer Vision and Pattern Recognition, Online, 2021.

网络首发:

标题: 利用散斑引导和扩散去噪的主动立体匹配方法

作者: 鲍国淦, 刘希, 邹勤

收稿日期: 2025-11-02

DOI: 10.13203/j.whugis20250207

引用格式:

鲍国淦, 刘希, 邹勤. 利用散斑引导和扩散去噪的主动立体匹配方法[J]. 武汉大学学报(信息科学版), 2025, DOI: 10.13203/j.whugis20250207 (BAO Guogan, LIU Xi, ZOU Qin. Active Stereo Matching Method Using Speckle Guidance and Diffusion Denoising [J]. *Geomatics and Information Science of Wuhan University*, 2025, DOI: 10.13203/j.whugis20250207)

网络首发文章内容和格式与正式出版会有细微差别, 请以正式出版文件为准!

您感兴趣的其他相关论文:

大气扩散模型 AERMOD 与 CALPUFF 对比研究及展望

李梅, 杨冬偶, 何望君

武汉大学学报(信息科学版), 2020, 45(8): 1245-1254

<https://ch.whu.edu.cn/article/doi/10.13203/j.whugis20200110>