

单位代码：10610

学 号：2021223040040

四川大學

硕士研究生学位论文

(学术学位)

题目：基于深度学习的散斑投影

立体匹配算法研究

培养单位：计算机学院（软件学院、智能科学与技术学院）

作者姓名：李根深

指导教师：张建伟 研究员

学位类别：工学硕士

学科专业：计算机科学与技术

论文答辩时间：二〇二四年五月

学位授予时间：二〇二四年六月

**Research on Speckle Projection Stereo Matching Algorithm
Based on Deep Learning**

**A dissertation submitted to Sichuan University
in partial fulfillment of the requirements
for the degree of**

**Master of Science in Engineering
in Computer Technology**

By

Genshen Li

Supervisor: Prof. Jianwei Zhang

Computer Science, Sichuan University, Chengdu, China

May, 2024

摘 要

在数字孪生、自动驾驶、生物安全识别等领域的快速演进中，三维重建技术愈发凸显其关键作用。基于结构光投影的三维重建因其在成本和精度之间的卓越平衡而备受青睐。尤其是基于散斑投影的双目立体视觉技术，凭借其在处理弱纹理表面上的卓越表现以及最高可实现单帧散斑投射的三维重建能力，备受研究人员的青睐。在散斑投影三维重建中，立体匹配算法被视为核心技术。然而，在当前阶段的技术中存在诸多限制。由于需要在固定距离投射散斑，对被测物体的距离和被测物体的深度造成了限制。当被测物体与系统距离发生变化或者物体的深度跨度过大时投射的散斑会发生尺寸的变化，同时由于投影的散斑不能随着深度改变焦距，导致投射的散斑发生离焦，进而使匹配精度的大幅度下降，限制了其在实际应用中的灵活性和鲁棒性。为了克服这一限制，本文着眼于研究基于深度学习的散斑立体匹配算法，实现对离焦的散斑特征进行恢复，以及实现对各种形状大小的散斑都具有良好检测效果。

(1) 针对散斑形状和大小对于立体匹配算法的影响，提出了一种多尺度空间通道注意力模块，并以此为基础构建了 NMSCANet 网络。该模块包含了空间注意力和通道注意力两个部分，空间注意力部分为多尺度空间注意力，使网络能够检测不同大小和形状的散斑特征，使特征提取更加完整；通道注意力部分旨在根据所提取的不同特征的重要程度进行特征的优化，使对于匹配网络最重要的特征通道能够以较高权重传入后续的步骤。结合这两种注意力使网络能够完整地提取各种大小和形状的散斑特征，并进行较好的特征优化，最终大幅度提高网络对于散斑大小变化的鲁棒性。实验结果表明，NMSCANet 表现出 8 倍点云重建稳定性于现有的立体匹配网络；同时，该网络立体匹配精度得到了大幅度的提高，EPE 下降了 35% 以上，N-PER 也下降了超过 62%。

(2) 针对散斑投影离焦导致匹配难的问题，本文提出了基于条件扩散模型的去离焦网络，并与立体匹配网络构建了双阶段网络。首先使用条件扩散模型对图片进行去模糊，将左右视图中离焦的散斑特征进行恢复，获得清晰的聚焦的图案后，再输入到立体匹配网络中进行视差的求解。本文构建了 UNet 型的噪声预测网络，使用残差连接块，提高特征在网络当中的表达与传播能力，此外，还引入多尺度空间通道注意力，使噪声的预测过程能够更加关注离焦部分。本文的扩散模型当中，将离焦的图片作为条件输入噪声预测模型，“指导”清晰图像的生成，将图像生成这一随机过程进行限制，生成的去离焦图片都是与离焦图片进行一一对应的。实验结果表明，所提出的去离焦方法能够有效地去除散斑投影的离焦，并提高立体匹配精度，并显著改善点云重建的稳定性，在真实拍摄的离焦场景下，相较于未去离焦时重建点云与真值点云的最近邻距离下降了 51.12%，距离标准差下降了 47.42%。

关键词：立体匹配；散斑投影；三维重建；注意力机制；去模糊

Abstract

In the rapidly evolving fields such as digital twins, autonomous driving, and biometric security recognition, the importance of 3D reconstruction technology is becoming increasingly prominent. The 3D reconstruction based on structured light projection is highly favored for its excellent balance between cost and accuracy. Particularly, the binocular stereo vision technology based on speckle projection is highly favored by researchers for its outstanding performance in handling weakly textured surfaces and its ability to achieve three-dimensional reconstruction with the highest achievable single-frame speckle projection. In speckle projection-based 3D reconstruction, stereo matching algorithms are considered as core technologies. However, there are several limitations in the current stage of the technology. The need to project speckle patterns at a fixed distance imposes restrictions on the distance to the measured object and the depth of the object being measured. Changes in the distance between the object being measured and the system or the large depth range of object will cause changes in the size of the projected speckles. Additionally, the inability of the projected speckles to change focus with depth variations can lead to defocusing of the projected patterns, resulting in a significant decrease in matching accuracy, limiting the flexibility and robustness of the technology in practical applications. To overcome these limitations, this study focuses on researching speckle stereo matching algorithms based on deep learning to restore defocused speckle features and achieve good detection performance for speckles of various shapes and sizes.

(1) To address the impact of speckle shape and size on the algorithm, a multi-scale spatial channel attention module is proposed, and the NMSCANet network is constructed based on this module. This module consists of two parts: spatial attention and channel attention. The spatial attention part incorporates multi-scale spatial attention to enable the network to detect speckle features of different sizes and shapes for more comprehensive feature extraction. The channel attention part aims to optimize features based on the importance of the extracted features, allowing the most important feature channels for the matching network to be passed with higher weights to subsequent steps. The combination of these two types of attention enables the network to fully extract speckle features of various sizes and shapes, perform better feature extraction, and significantly improve the network's robustness to changes in speckle size. Experimental results show that NMSCANet demonstrates 8 times more stable point cloud reconstruction than existing stereo matching networks. Additionally, the stereo matching accuracy of the network is significantly improved, with an EPE reduction of over 35% and an N-PER reduction of over 62%.

(2) To address the challenge of difficulty in matching caused by defocusing in speckle pro-

jection, this paper proposes a defocus removal network based on a conditional diffusion model, and constructs a two-stage network with a stereo matching network. Initially, the conditional diffusion model is used to deblur images, restoring the defocused speckle features in the left and right views to obtain clear focused patterns, which are then input into the stereo matching network for solving the stereo disparity. The paper builds a UNet-like noise prediction network with residual connection blocks to enhance the representation and propagation capabilities of features within the network. Additionally, a multi-scale spatial-channel attention mechanism is introduced to allow the noise prediction process to focus more on the defocused regions. In the diffusion model proposed in this paper, defocused images are used as conditional inputs to the noise prediction model to "guide" the generation of clear images, restricting the random process of image generation to ensure that the generated defocused images correspond one-to-one with the defocused images. Experimental results demonstrate that the proposed defocus removal method can effectively eliminate defocusing in speckle projection, improve stereo matching accuracy, and significantly enhance the stability of point cloud reconstruction. In real defocused scenes, compared to unrepaired defocusing, the nearest neighbor distance between the reconstructed point cloud and the ground truth point cloud decreased by 51.12%, and the distance standard deviation decreased by 47.42%.

Keywords: Stereo matching; speckle projection; 3D reconstruction; attention block; deblurring

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 三维重建技术研究现状.....	2
1.2.2 双目立体视觉研究现状.....	3
1.2.3 去离焦研究现状.....	6
1.3 本文主要研究内容.....	7
1.4 本文组织架构.....	8
第 2 章 相关理论基础	9
2.1 双目立体视觉.....	9
2.1.1 双目视觉原理.....	9
2.1.2 结构光编码.....	10
2.1.3 条纹投影轮廓术.....	10
2.1.4 散斑投影轮廓术.....	11
2.1.5 投影仪成像模型.....	12
2.2 基于深度学习的立体匹配算法	13
2.2.1 基于回归任务的立体匹配算法.....	13
2.2.2 基于代价体构建的立体匹配算法.....	14
2.3 深度学习相关理论.....	14
2.3.1 卷积神经网络.....	15
2.3.2 扩大感受野的方法.....	16
2.3.3 基于卷积的注意力模块.....	17
2.3.4 扩散模型.....	18
2.4 本章小结.....	21
第 3 章 数据集的构建	23
3.1 实验环境与数据获取.....	23
3.1.1 真实数据的获取.....	23
3.1.2 仿真数据的获取.....	24
3.2 散斑尺寸变化与离焦的仿真	26
3.2.1 散斑尺寸变化数据集.....	26
3.2.2 散斑离焦数据集.....	28
3.3 数据集的汇总.....	29
3.4 本章小结.....	30
第 4 章 基于多尺度空间通道注意力的立体匹配算法	31

4.1 引言.....	31
4.2 多尺度空间通道注意力网络的构建	31
4.2.1 散斑尺寸与特征提取的关系.....	32
4.2.2 NMSCA 模块	34
4.2.3 损失函数.....	36
4.3 实验结果与分析.....	37
4.3.1 数据集.....	37
4.3.2 对比网络.....	37
4.3.3 评价指标.....	38
4.3.4 对比实验.....	38
4.3.5 泛化实验.....	43
4.3.6 消融实验.....	44
4.3.7 有效性实验.....	46
4.4 本章小结.....	47
第 5 章 基于扩散模型的投影散斑去离焦算法	49
5.1 引言.....	49
5.2 去离焦网络的构建.....	49
5.2.1 噪声预测网络.....	49
5.2.2 正向扩散过程.....	51
5.2.3 逆向去离焦过程.....	52
5.3 实验结果与分析.....	52
5.3.1 离焦的融合	52
5.3.2 对比网络.....	53
5.3.3 参数设置与评价指标.....	53
5.3.4 去离焦实验.....	54
5.3.5 三维重建实验.....	56
5.4 本章小结.....	60
第 6 章 结论与展望	63
6.1 本文工作总结.....	63
6.2 未来工作展望.....	64
参考文献.....	65

插图目录

图 1.1	散斑投影立体视觉应用	1
图 1.2	多视角成像原理 ^[7]	3
图 2.1	双目视觉原理图	9
图 2.2	匹配示意图	11
图 2.3	DLP 原理图 ^[72]	12
图 2.4	投影仪成像示意图	12
图 2.5	基于回归的立体匹配	13
图 2.6	基于代价体构建的立体匹配	14
图 2.7	卷积操作	15
图 2.8	池化操作	15
图 2.9	卷积的堆叠	16
图 2.10	空洞卷积	17
图 2.11	通道注意力	18
图 2.12	空间注意力	19
图 3.1	数据集构建流程	23
图 3.2	立体匹配数据获取流程	24
图 3.3	仿真系统的构建	25
图 3.4	投影比例与散斑大小示意图	27
图 3.5	不同尺寸散斑成像图	27
图 3.6	投影仪离焦	28
图 3.7	散斑离焦投影成像	29
图 4.1	NMSCANet 的总体框架图	32
图 4.2	散斑尺寸与特征关系示意图	33
图 4.3	NMSCA 结构示意图	35
图 4.4	人脸点云重建结果	39
图 4.5	人脸点云误差图	40
图 4.6	不同散斑大小各模型对比结果示意图	41
图 4.7	不同模型在球体和平面上的比较折线图	42
图 4.8	球体和平面的点云结果	42
图 4.9	面具三维重建结果	43
图 4.10	真实人脸重建结果	44
图 4.11	消融实验的对比折线图	45

图 4.12	消融实验中点云重建结果	46
图 5.1	噪声预测网络.....	50
图 5.2	残差网络块.....	50
图 5.3	聚焦最近处.....	52
图 5.4	聚焦中间点处.....	53
图 5.5	最近点聚焦的去离焦结果对比.....	55
图 5.6	中间聚焦的去离焦结果对比.....	55
图 5.7	各离焦程度对比折线图	56
图 5.8	不同离焦程度的恢复结果	57
图 5.9	真实平面检测结果.....	58
图 5.10	去离焦三维重建结果.....	59
图 5.11	不同离焦程度的三维重建结果.....	60

表格目录

表 3.1	采集系统环境.....	24
表 3.2	数据集汇总	29
表 4.1	0.7 散斑大小下的匹配结果.....	41
表 4.2	消融实验模型设置	44
表 4.3	有效性实验结果	46
表 5.1	去离焦评价指标对比结果	56
表 5.2	立体匹配网络重建结果统计	58

第1章 绪论

1.1 研究背景及意义

在计算机视觉领域，三维重建技术扮演着不可或缺的角色。这项技术利用诸如双目视觉系统、单张图像以及雷达扫描等多种手段，将现实世界中的三维场景或物体数字化，从而在计算机环境中模拟出真实世界的场景与物体。随着数字化时代的蓬勃发展，三维重建技术的应用范围不断扩大。除了在元宇宙构建中发挥着关键作用之外，它在医学影像处理、工业检测等领域也具有重要的意义。比如，在虚拟现实领域，可以实现对文物的数字化保护；在生物安全识别领域，精准的三维形貌重建可以实现高精度的安全屏障；而在工业检测领域，对微小零件或焊接点的重建则能够支持快速的缺陷检测和形变测量，进而提高生产效率和质量控制水平。如图1.1所示。




图 1.1 散斑投影立体视觉应用

Figure 1.1 Application of speckle projection 3D reconstruction

在众多三维重建系统中，双目立体视觉技术以其低成本、高精度和系统简单等优势而备受瞩目。然而，该技术在弱纹理区域容易出现匹配错误的问题。为了解决这一难题，研究人员引入了结构光投影技术，通过无接触的方式丰富被测物体表面的纹理信息，以实现精准匹配和高精度的三维重建。在诸多结构光编码方法中，散斑图案因其具有全局唯一性和随机性而被广泛采用，能够有效地纹理化被测物体表面，从而实现高精度的三维重建。此外，散斑投影技术还能够实现基于单帧结构光投射的三维重建，相较于条纹投影和格雷码投影，其具备更高的效率，更适用于动态场景的重建。

在基于散斑投影的三维重建技术中，立体匹配算法则显得尤为关键。这种算法需要准确地在左右图像中找到同名点，并计算出视差，以实现高精度的三维重建。然而，在当前的基于散斑投影的三维重建系统中，通常需要在固定距离投射固定大小的散斑，以确保立体匹配算法能够准确地匹配左右视图。然而，随着工业和自动驾驶技术的迅速发展，对多距离测量和大景深测量的需求也在不断增加。这给基于散斑投影的三维重建技

术带来了新的挑战,例如工作距离的限制和测量景深受限等问题,这些都可能导致匹配精度的下降。因此,只有立体匹配算法能够适应各种散斑大小和离焦程度,才能进一步拓展该技术的应用范围,为工业制造、文化遗产保护等领域带来更多的创新和发展机会,从而推动数字化时代的进步。

1.2 国内外研究现状

1.2.1 三维重建技术研究现状

三维重建技术旨在从二维图像或其他传感器数据中恢复三维场景的形状、结构和纹理。根据所使用的设备或者方法的不同可以分为以下几种:基于激光雷达的三维扫描方法,基于多视角图像的三维重建,直接使用结构光编码的三维重建技术。

1.2.1.1 基于激光雷达的三维重建


在计算机视觉领域可以使用激光直接对被测场景或者物体进行探测,向被测物体发射激光过后,使用飞行时间法(Time of flight, TOF)^[1]计算发射激光时间与接收信号的时间差,结合光速计算得到信号源与被测物体之间的距离,以此实现对场景的三维重建。该方法重建结果一般为点云,后期需要结合点云降噪、点云拼接等处理,由于是直接进行扫描,一般的精度较高,点云的精细程度与激光发射器的密度成正相关。该方法虽然能够直接实现毫米级的三维重建,但是该方法要使用的设备造价较高,对于大众的应用较为困难。因此本文主要研究使用成本较为低的相机作为成像设备来实现三维重建。

1.2.1.2 基于多视角图像的三维重建

基于图像的三维重建主要通过多视角拍摄同一个物体的二维图像,结合三角测量原理从二维图像中恢复三维信息。其成像原理如图1.2所示。有的研究人员^{[2][3]}引入相机的运动信息,实现了单目相机从运动到三维结构信息(Structure-from-Motion, SFM);有的研究人员直接利用多个相机对同一个物体进行同时的拍摄,然后使用多视角视觉进行三维信息的重建。这样可以避免单目相机多次拍摄和移动中带来的误差信息,从而进行更高精度的重建^{[4][5][6]}。

1.2.1.3 基于结构光编码的三维重建技术

基于结构光投影的单目三维重建技术是一种主动三维测量方法,它通过向目标物体表面投射结构化的光源,再使用相机拍摄经过调制后光场,最后从图像当中解析出被测物体的三维信息。最常使用的是正弦条纹图片。通过一系列带有相位信息的正弦图像进行投射。Zhang 等人^[8]使用傅里叶变换求得相位。而 Zuo 等人^[9]采用相移法,利用多

图 1.2 多视角成像原理^[7]Figure 1.2 3D reconstruction from multi-views^[7]

张有相移的图片实现更加高精度的相位解析。获取到相位过后再使用相位高度映射算法^[10]即可实现三维重建。随着深度学习技术的不断发展，Zuo 等人^[11]使用模拟相移法解相的过程取得了不错的精度；Nguyen 等人^[12]则使用深度学习实现相移条纹和条纹级数的预测，大大提高相位计算的速度，可用于动态的三维测量当中。同时 Wang 等人^[13]更是将相位解析这一步去除，提出了端到端的网络模型，直接从条纹图当中去预测深度。大大提高了三维重建系统的效率。

1.2.2 双目立体视觉研究现状

在众多三维重建技术中，基于结构光编码的双目立体视觉的三维重建技术具有设备简单（只需要两个相机加一个投影仪）、匹配精度高和方法简单（立体匹配技术）等优势。在工业制造、文化遗产保护等领域都有广泛的应用。因此，本文的研究重点主要是与该方法相关。本小节主要介绍关于双目立体视觉的研究现状。

1.2.2.1 传统匹配算法

在双目立体视觉中，最重要的是立体匹配算法，它是从左右两张图片中获取同名点计算相位的一种方法。它一般由四个步骤组成：计算匹配代价，聚合代价，计算视差以及最后的优化视差。根据在计算匹配代价和聚合代价部分所使用的计算策略不同，分为局部算法和全局算法两大类。

（1）局部算法：

局部算法的核心是使用某种代价函数（相似度量），在左右视图中取一个局部大小块，使用代价函数计算它们的匹配代价，即确认这两个块的相似度。经过滑动窗口的检

测,构建代价体,最后能根据代价体确认视差。最简单的代价计算是直接使用图像灰度值的绝对差(Absolute Difference, AD)、平方差(Squared Difference, SD)或者图像梯度进行计算,也有使用归一化互相关进行计算的。但直接使用灰度值进行计算容易受到光照的影响。其中基于 Census 变换的立体匹配算法是较为经典的立体匹配算法之一^[14]。后来,Mei 等人^[15]结合了 AD 算法和 Census 算法的优势,构建了 AD-Census 算法,使其在弱纹理区域和光照的影响下也能够进行较好的匹配。受到这种组合代价计算的启发,Hamzah 等人^[16]在 AD-Census 的基础上融入图像梯度,以提高算法对辐射失真和光照变化时的鲁棒性。而 Hong 等人^[17]更进一步,将 AD、SD、Census、Rank^[18-19]四个代价函数进行融合,进一步提高匹配代价计算的准确性和鲁棒性。Micheal 等人^[20]则从窗口设计的角度出发,提出了 PatchMatch 算法,舍弃固定窗口的模式,考虑三维物体的不同平面使用不同的倾斜窗口,取得了十分出色的匹配结果,但执行效率较低,比较耗时。为了提高匹配算法的速度,Yang 等人^[21]将匹配图构造为一个树形结构,使用树形滤波,不需要进行整行的匹配计算,大大提升了算法的效率,但其在跨区域中容易出现聚合错误。戈豪豪^[22]则通过引入区域分割以及分割约束,很好地控制了跨区域传播的问题,并保留了原算法的匹配精度。

(2) 全局算法:

全局算法的核心是构建一个全局的能量函数,将多个像素点的视差求解信息放入能量函数中,然后通过马尔可夫随机场等方式在匹配过程中求解能量函数的最小值,从而求得这些像素点的视差值。该方法考虑了多个甚至全场的结构信息,从而使各个像素的视差值精度较高,但由于计算量的增加,计算效率较低。因此,大多数研究人员都希望提高全局算法的运行效率。何高奇等人^[23]提出了一种点对点的动态规划匹配方法,大大缩短了匹配时间,但在计算过程中只对极线上的像素进行了扫描,导致视差图容易出现条纹现象。后来,罗嗣卿团队^[24]和 Li 的团队^[25]分别提出了方向滤波的处理方法和使用最近邻搜索提前提取特征点的匹配方法来解决条纹现象。随后,Hu 等人^[26]引入了单向四连接树来解决图像边缘容易导致匹配错误的问题,并结合快速的动态规划算法,使精度和匹配速度都得到了不错的提升。之后,Sun 等人^[27]提出将置信扩展算法与立体匹配融合,综合考虑视差概率和能量函数,并结合局部的图像分割约束取得了不错的匹配效果。随后,Ahmadzadeh 等人^[28]利用并行处理的计算方式和多核系统平台,大大提高了运行效率,解决了该算法需要长时间运行的问题。Yi 等人^[29]则主要解决立体匹配中遮挡导致的错误问题,根据层次置信扩展的原理,采用对称区块匹配的方式有效降低了误匹配的概率。刘忠艳等人^[30]进一步提出了一种新的使用图像块进行置信传播的匹配算法,通过采用分水岭图像分割方法,显著降低了基于置信度传播算法的误匹配现象,大大提高了匹配的精度。

1.2.2.2 基于深度学习的匹配算法

最近,深度学习网络在计算机视觉任务中取得了巨大进展,许多出色的立体匹配网络已经涌现,并在精度和速度上表现优于传统的立体匹配算法。Zbontar 等人^[31]首先将卷积神经网络与传统算法的匹配代价计算相结合,利用神经网络优秀的特征提取能力,大大提高了匹配的精度。但该方法仍需要结合传统算法的计算步骤,没有实现端到端的视差生成。而 Mayer 等人^[32]则首先尝试直接使用深度学习网络优秀的特征提取和表达能力,通过回归的方式构建了一个网络,实现了第一个端到端的立体匹配网络。而 Yang 等人^[33]利用图像分割的线索指导网络进行视差生成,提高了匹配的精度。但由于这两种方法没有使用图像中的结构信息,匹配精度仍然较低。随后, Kendal 等人^[34]舍弃了基于回归的立体匹配方式,提出了一种新的端到端立体匹配网络,使用权重共享的特征提取模块提取了空间结构信息,并构建了一个代价体,通过对代价体进行视差回归计算,大大提高了网络模型的精度。自此以后,许多研究人员都采用了该匹配方案,通过专注于立体匹配网络的三个方面:特征提取、代价体构建和视差回归来增强匹配结果。一些研究者致力于改变特征提取以提高立体匹配模型的准确性。其中, Chang 等人^[35]将金字塔池化结构引入特征提取中,以获取不同尺度的特征。而 Kang 等人^[36]则采用空洞卷积的形式来获取多尺度的特征信息,提高匹配精度和对弱纹理区域的鲁棒性。Nguyen 等人^[37]同时采用空间金字塔和空洞卷积,以实现更大的感受野,提高特征提取的能力,构建更丰富的代价体,从而最终提高匹配的精度。张伟等人^[38]在特征提取中加入联合注意力,根据空间和通道的重要程度赋予不同的权重,提高匹配精度。也有一些研究者从代价体构建的角度进行修改。Kendal 等人^[34]提出的代价体是通过将左右视图的特征进行对应位置的拼接得到的,由于直接的拼接导致过多冗余信息传入后续的步骤,导致计算速度较慢。而 Guo 等人^[39]为了解决这个问题,在进行拼接之前,将左右图像的特征分组,在各组内计算相关性后再进行拼接,大幅度减少了冗余信息,并保留左右特征的相关信息,从而在保证精度的情况下提高了计算效率。而 Xu 等人^[40]首先使用相关性计算代价体的方式获取一个代价体注意力,然后用该注意力对拼接的代价进行提炼,去除冗余信息。相比于 Guo^[39]的方法,该方法更好地保留了在拼接代价体中的结构信息,实现了更高的精度和效率。党宏社等人^[41]则使用卷积注意力网络来代替 Xu 网络中^[40]的基于相关代价体的注意力计算,使注意力权重更加精准与鲁棒,进一步提高精度。也有研究人员将最近大火的 Transformer^[42]引入到立体匹配当中,打破了传统代价体构建的方式,从序列生成的角度进行匹配,获得了不错的匹配精度,但是该方法需要消耗大量的时间,且对于分辨率较大的图片处理较为困难。而 Li 等人^[43]则更是打破了深度学习网络对于视差图真值的需要,采用自监督的方式来进行视差图的生成,虽然给研究人员提供了一种新的立体匹配思路,但相较于现在主流的匹配网络,其精度与速度仍有待提高。

1.2.2.3 单帧散斑投射立体匹配算法

相较于传统的基于环境光的立体匹配算法,增加散斑的投射可以很好地解决弱纹理或无纹理区域的问题。因此,将优秀的立体匹配算法与散斑投射相结合也是研究的热点之一。例如,Xu 等人^[44]使用红外散斑投射辅助双目立体系统,使其能够在室内实现对于弱纹理区域更好的匹配。但其散斑投影并不是直接用于双目系统,而是用于一个单目红外系统,实际上需要两套系统才能实现散斑投射的立体视觉。若要实现基于散斑投射的立体匹配算法,散斑图案的设计需要保证全局的唯一性与随机性,立体匹配只需要单帧的散斑投射即可实现三维重建。Zhou 等人^[45]设计的黑白二值散斑图案很好地实现了单帧投射的立体匹配算法。许多研究人员都开始将立体匹配与散斑投射相结合,以期实现高精度的三维重建。Guo 等人^[46]在 SGM 的基础上进行了优化,修改了对于相近位置的惩罚项,并减少了短基线的立体匹配容易遇到的问题,构建了适用于医学内窥镜的散斑三维成像系统。同时,随着深度学习的逐渐成熟,许多研究人员开始研究基于单帧散斑投射和深度学习的立体匹配算法,以期实现高精度的单帧结构光照射的三维重建。Yin 等人^[47]提出了一种基于单次拍摄散斑的端到端立体匹配网络的三维重建方法。他们将多尺度残差模块引入特征提取中,实现了对单帧散斑投射的亚像素匹配结果。同时,他们引入了一个轻量级的 3D-U-Net 网络来实现高效的四维代价体聚合,以实现更高的匹配效率。该方法很好地结合了立体匹配网络与散斑投射,为研究人员开辟了新的思路。最近,Wang 等人^[48]采用了密集网络进行特征提取,进一步提高了 SPP 的准确性,并融合了串联代价体积和相关性代价体积以提升匹配速度。尽管这些先前的工作在实现 SSPP 目标方面取得了进展,并在立体匹配网络的各个方面都有所改进以实现更准确的匹配结果,但它们都相当依赖系统的稳定性,无法实现鲁棒的三维重建。目前的这些网络都没有考虑到散斑发生改变(如大小变化)或散斑发生离焦导致模糊等问题对匹配网络的影响。

1.2.3 去离焦研究现状

在基于结构光投影的双目立体视觉中,结构清晰的结构光图案是必要的。除了一些特定的场景希望通过相机的离焦使二值编码的图像模糊为条纹图像^[49-51]以提高投影的速率外,投影仪的离焦对于双目成像系统来说都是起到负面作用的。图像的去离焦任务是图像去模糊的一种,目前关于去模糊的方法主要分为两种:非盲去模糊与盲去模糊。其中非盲去模糊^[52-54]指对已知模糊核或离焦图的情况下对模糊的图像进行反卷积的图像恢复。近年来,随着深度学习的快速发展,基于深度学习的端到端盲去模糊逐渐成为主流。Fei 等人^[55]首先使用深度学习网络在自适应光学领域(Adaptive Optics, AO)中实现了端到端的退化图像重构。Kupyn 等人^[56]利用对抗生成网络(GAN)将去模糊变为图像生成的任务,并取得了不错的效果。但该方法会存在预测不稳定引入新的噪声等问题。Zhao 等人^[57]在此基础上引入一个新的生成器用于预测离焦区域,并结合离焦区域与模糊图片进行更精确的清晰图像生成,将图像去模糊变成两步走方式,进一步提高

了去模糊的效果。Abuolaim 的团队^[58-59]则利用全像素双核对焦传感器获取的数据与卷积神经网络实现了端到端的图像去模糊效果。Quan 等人^[60]利用像素级的高斯扩散核以及一个轻量级的多尺度循环网络实现了单张图像的去离焦，通过将传统算法的扩散核结合到深度学习中，实现了将一张离焦模糊的图片变成一张全聚焦的清晰图片。Lee 等人^[61]提出一种新的迭代滤波卷积层，将去模糊滤波器建模为一系列小型可分离滤波器的堆叠，对大面积的离焦模糊取得了不错的成绩。Ma 等人^[62]则创新性地使用卷积神经网络预测一张输入图片的离焦程度图，再根据离焦程度图进行不同程度地去离焦，取得了很好的图像去离焦效果。后来，Zamir 等人^[63]将多头注意力应用于图像的去模糊，取得了不错的效果，但其中自注意力的计算量过大，难以实际应用于大分辨率图片的去模糊。最近，Ruan 等人^[64]通过使用具有大卷积核的卷积神经网络来模拟多头注意力的长上下文关注能力，将基于卷积神经网络的图像去模糊能力提升到与基于多头注意力的相当。

1.3 本文主要研究内容

本文以实现鲁棒的基于散斑投射的立体匹配算法为目标，讨论在基于散斑投射的立体系统中，对于整个匹配算法与三维重建精度有较大影响的因素，通过分析其影响匹配的原因，构建合适的网络来解决这一问题，使网络能够提高鲁棒性。本文主要讨论散斑大小变化以及散斑离焦这两种情况下对于立体匹配算法的影响，并针对他们分别提出好的解决方案。为了完成该研究，首先搭建了一个基于散斑投射的双目系统，用于拍摄真实的数据集。同时为了扩充数据集以及更好地量化控制，本文要研究的散斑尺寸的变化以及投影仪离焦的情况，本文还使用了数字孪生的技术，搭建了仿真采集系统，根据真实双目系统的标定参数摆放虚拟相机以及调整相机的内参，尽可能保证真实与仿真系统的一致性。然后，在仿真系统里面进行大量数据的采集用于训练网络，并使用仿真系统进行了各种散斑尺寸照射下的图片对生成以及各种投影仪离焦程度下的图片仿真。帮助进行问题的分析与所提方法可行性的验证。本文针对散斑大小与散斑离焦的主要工作如下：

(1) 针对散斑立体匹配网络容易受到散斑大小形状变化的影响，提出了一种单帧散斑多尺度空间通道注意力立体匹配网络 (NMSCANet, Normalize multi scale spatial channel attention Net)。通过在立体匹配网络的特征提取阶段构建归一化的多尺度空间注意力与通道注意力。多尺度空间注意力帮助网络实现对于多尺度散斑特征的提取，通道注意力帮助网络对于不同特征通道权重更新，进行更好的散斑特征选优。同时结合代价体注意力对拼接的代价体进行冗余信息的去除，实现了较好的匹配效果。另外，该网络可以在同一散斑尺寸下进行训练而达到针对不同散斑大小的照射都能够实现较好的匹配效果，大大提高了立体匹配网络对于散斑大小形状变化的鲁棒性。

(2) 针对散斑离焦的情况下，本文提出了一种基于条件扩散模型的散斑去离焦网络。

实现将投影仪投射出来的离焦散斑进行去模糊。在这一部分，首先进行了离焦图像的模拟，并采用多帧融合的方式构建随深度变化离焦程度发生变化的仿真数据集。接着构建了噪声预测网络，利用条件扩散模型的原理对图像的离焦部分进行恢复。最后与立体匹配网络构建双阶段网络，实现对于离焦的鲁棒匹配。实验结果表明该方法可以较好地解决散斑立体成像当中的散斑离焦问题，提高三维点云重建的稳定性。

1.4 本文组织架构

本文的各章节内容如下：

第一章：绪论。这一章节介绍了三维重建技术的研究背景及意义，探讨了结构光双目系统在三维重建中的应用，以及基于散斑投影的立体视觉技术的优势和面临的挑战。同时介绍了基于散斑投影的三维重建技术与图像去离焦的研究现状。

第二章：相关理论基础。本章详细介绍了双目立体投影轮廓术的原理，包括双目立体视觉原理、结构光立体匹配等。同时，讨论了基于深度学习的立体匹配算法，以及深度学习相关理论。此外，还描述了数据集的采集系统和实验环境。

第三章：数据集的构建。本章详细介绍了在本文所使用的数据采集系统以及数据处理的流程。并详细介绍了本文构建仿真采集系统的方法与流程。并对本文所用到的数据集进行了详细的总结与描述，方便后续研究内容的展开。

第四章：基于多尺度空间通道注意力的立体匹配算法研究。这一章节重点研究了散斑形状和大小对算法影响的问题，提出了多尺度空间通道注意力模块，并构建了 NM-SCANet 网络。通过实验验证了该网络在点云重建稳定性和立体匹配精度上的优势。

第五章：基于扩散模型的投影散斑去离焦研究。本章探讨了散斑离焦对立体匹配精度影响的问题，提出了基于条件扩散模型的去离焦方法，以提高三维重建算法的鲁棒性。

第六章：总结与展望。最后一章总结了整篇论文的研究成果，并对未来的研究方向提出了展望。

第2章 相关理论基础

2.1 双目立体视觉

2.1.1 双目视觉原理

双目立体视觉是一种重要的计算机视觉技术，通过模拟人双眼感知三维世界的方式，让计算机能够感知三维的世界，其示意图如图2.1所示。该技术使用左右两个相机拍摄相同场景的不同角度，利用两个相机在世界中摆放位置和角度不同造成的同一个物体在成像平面的不同位置，再结合相机的标定参数就可以估计场景中的深度和距离，生成计算机能够理解的三维点云或者三维模型。该技术的实现主要包括以下四个步骤：




图 2.1 双目视觉原理图

Figure 2.1 Binocular vision principle

(1) 相机标定：要让计算机正确感知三维世界，要首先确定两个相机基本参数如相机的焦距、主点坐标以及畸变参数这些内部参数和相机的旋转、平移矩阵这些外部参数。准确获得相机的内外参数是能够准确地对三维世界进行重建地重要前提。通常使用两个相机拍摄棋盘格或圆点等已知几何形状的标定板，并处理这些图像来计算相机的参数。

(2) 图像矫正：图像矫正包括去除畸变和极线矫正两步。在获得两个相机的内外参数过后，需要对图像进行矫正以消除图像畸变，然后通过极线矫正，将搜索同名点的二维搜索问题转化为一维搜索问题，从而提高匹配的效率和准确性。使用前面获取的相机标定参数，就可以获取两个相机的畸变参数，并计算出两个相机成像平面之间的旋转平

移变换矩阵。最后使用畸变参数和变换矩阵就可以实现图像的矫正。

(3) 立体匹配: 立体匹配是双目立体视觉中的核心步骤,用于在左右图像当中寻找同名点并计算视差(即同名点在左右两个视图当中的水平偏移量)。常见的立体匹配算法包括基于像素级的匹配(如局部匹配^[15-17,20]、全局匹配^[24-25,28,30])、基于特征点的匹配(如 SIFT^[65-66]、SURF^[67-68])以及基于深度学习的匹配^[32,34-35,40]。获得视差图过后就可以利用如图2.1中所示的公式进行深度的计算。

(4) 三维重建: 三维重建的目标是将图像中的像素点映射回真实世界三维空间,从而创建场景或物体的三维点云或者三维模型。这可以通过将视差值转换为深度值,然后将深度值与像素坐标一起投影回三维空间来实现。还可以使用其他技术(如点云配准、曲面拟合)来进一步改善三维重建的质量和准确性。

2.1.2 结构光编码

在双目立体视觉当中,有一个难题是弱纹理区域的匹配问题。当需要重建的物体本身没有丰富的结构或者纹理信息时,左右两个图像当中较难提取到唯一的特征信息,在进行立体匹配时就较难确认同名点在左右两个图像当中的位置。一些研究者就通过给被摄物体投射结构光,对物体进行结构光编码^[8]或者给被摄物体添加丰富的纹理信息^[44-45,47]。使每一个特征点都能在两个图像中找到对应的位置进行立体匹配获得视差图。其示意图如图2.2所示。目前的研究热点是基于相移条纹投影^[9]的条纹投影立体视觉和基于单帧散斑投影的散斑投影立体视觉。其中条纹投影立体视觉利用多帧周期性的相位图片对整个场景进行编码,然后求出场景当中不同位置的唯一相位来增加特征信息。而散斑投影立体视觉则是通过投影仪直接给无纹理的被摄场景打上具有唯一性特征的散斑纹理。通过两种方式给左右视图增加特征后,就可以对左右视图进行特征的匹配求解视差图了。

2.1.3 条纹投影轮廓术

条纹投影轮廓测量是目前结构光投影轮廓术中研究最为广泛,精度也最高的测量方法。该方法利用周期性的多种频率与多步相移的正弦条纹来编码被测物体,然后利用多频外差法、多步相移法等相位求解方法求解左右拍摄图像的绝对相位,利用同一个物体在同样的编码条纹下所求相位相同这一特性,对左右图片进行相位匹配即可实现精准高效的立体匹配^[69-70],进而实现三维重建。由于本文的研究都在静态下,可以使用多步相移法计算左右视图的精准相位,利用该左右相位进行相位匹配的视差图可以作为高精度的真值。因此本文所有数据集的真值均是由多步相移法求得。在条纹投影立体视觉中,投射第 i 张条纹图片过后,相机获取的图案中各像素的光照强度 I 如公式(2-1)所示:

$$I_i(x, y) = A(x, y) + B(x, y) \cos \left(\varphi(x, y) - \frac{2\pi i}{N} \right) \quad (2-1)$$




图 2.2 匹配示意图

Figure 2.2 Speckle match

其中 A 为环境光强, B 为投射图案的光强, 它受条纹 $\cos$ 图案的调制, 不同的 $i \in [1, N]$ 表示不同投射步数, φ 为截断相位, 结合投射的 4 步低频条纹, 4 步中频, 10 步高频条纹, 使用相位轮廓术可以求得截断相位 (如公式 (2-2) 所示)。由于在截断相位 φ 使用了反正切函数 $\arctan$, 所得截断相位包裹在 $(-\pi, \pi]$ 。在整张图片当中, 由于包裹相位仍然没有全局的唯一性, 为了更好地进行相位匹配, 需要进行相位展开, 根据不同的展开方式, 可以分为时间相位展开^[9]与空间相位展开^[71]。相位展开过后, 在全局不同的像素位置, 就有唯一对应的相位值, 即可以进行后续的相位匹配。

$$\varphi(x, y) = \arctan \frac{\sum_{i=1}^N I_i(x, y) \sin(\frac{2\pi i}{N})}{\sum_{i=1}^N I_i(x, y) \cos(\frac{2\pi i}{N})} \quad (2-2)$$

2.1.4 散斑投影轮廓术

在结构光立体匹配当中, 散斑投影立体视觉是一种不可或缺的三维重建方式。该技术通过向被测物体投射具有随机性和唯一性的散斑图案, 丰富被测物体表面的纹理信息, 为立体匹配提供丰富的特征点, 使同名点的寻找和视差图的计算更加方便和快速。与条纹投影立体视觉相比, 散斑投影立体视觉做到了更好的精度与执行速度的平衡。散斑投影由于散斑图案的唯一性, 不需要进行捕获图像的编码和解码过程, 在立体匹配之前不需要前置的操作步骤, 拥有较高的执行效率。同时, 散斑投射可以实现单帧三维重建, 避免了多次拍摄时物体运动或者环境变化带来的误差, 更加适用于动态场景的实时重建与测量。在散斑投影立体视觉当中, 所投射的散斑是重建过程中精度的重要依赖因素, 根据不同的应用场景和目标物体的特性, 选择合适的散斑图案和参数可以帮助实现更好的三维重建。本文采用 Zhou^[45] 文中所提到的散斑构建方式, 构建方形的黑白散斑,

投射到被摄物体，用于丰富物体的纹理信息，具体的双目数据投射采集流程可参考本文中的第三章内容。

2.1.5 投影仪成像模型

在结构光立体视觉当中，都需要使用数字投影仪给被摄场景投射结构光，其中投影仪是不可或缺的存在。本小节将主要介绍数字光源投影仪的成像模型，以此探讨在鲁棒散斑投影三维重建方法中投影仪方可能存在的问题。本研究所采用的投影仪为德州仪器生产的 DLP4500 数字投影仪。它的成像原理如图2.3所示，其中的 DMD（Digital micromirror device）是整个系统中的关键，它是拥有很多微小的可调反射面的一个反射装置。通过控制色轮快速转动与反射面的开关来融合图案和颜色。该投影仪的成像模型



图 2.3 DLP 原理图^[72]

Figure 2.3 Principles of DLP^[72]

可以抽象成如图2.4所示的小孔成像的逆向模型。从图中可以发现，透镜的对焦位置需要与 物体的摆放位置在同一平面才能够实现较好的投影成像。当调整透镜的焦距可以




图 2.4 投影仪成像示意图

Figure 2.4 Diagram of projector imaging

调整对焦的位置，在散斑立体视觉中如果保持投影仪与物体距离不变，此时物体上所呈

现的散斑就会出现离焦模糊的散斑图像。此时可以将被测物体也移动到投影仪的焦平面上去，但是此时物体与投影仪之间的距离发生变化，投射比发生变化，投射出来的图案大小发生改变，散斑的大小也会随之改变。在散斑投影立体视觉当中，散斑大小的改变和散斑的离焦都会给后续的立体匹配带来巨大的挑战。本文的研究重点便是从深度学习网络设计的角度来提高散斑投影立体视觉面对这两种情况的鲁棒性，最终实现不论投影仪与物体摆放关系如何都能够实现基于散斑投影的三维重建。

2.2 基于深度学习的立体匹配算法

自 Zbontar 等人^[31]将深度学习模型引入到立体匹配算法当中，越来越多的研究人员参与到基于深度学习的立体匹配算法当中。并且随着深度学习技术的快速发展，利用深度学习更优秀的特征检测与表达能力，立体匹配算法的也得到了长足的发展，其精度和速度相较于传统的立体匹配算法得到了很大的提升。根据所采用的深度学习模型不同，这些算法可以分为基于回归任务的立体匹配算法与基于代价体构建的立体匹配算法。

2.2.1 基于回归任务的立体匹配算法

基于回归任务的立体匹配算法是利用深度神经网络较强的非线性的数据映射能力，直接忽略左右图像当中的结构信息，将图像输入到一个编码器-解码器型的网络当中，直接从纹理信息映射到深度信息或视差图，如图2.5所示。通过这种端到端的方式虽然能够进行深度信息的估计，但是需要大量的标注数据进行训练，所需的数据成本巨大。同时，由于该方法对于数据的高度依赖关系，其泛化能力较差，很难得到大规模的应用。




图 2.5 基于回归的立体匹配

Figure 2.5 Regression based stereo matching

2.2.2 基于代价体构建的立体匹配算法

目前主流的基于深度学习的立体匹配算法是基于代价体构建的算法。这种算法结合了传统算法与深度学习方法的优点，方法简单但有效，适用于各种场景，目前得到了广泛的研究和应用。其主要流程包括三步：特征提取，代价体构建，视差回归，其示意图如图2.6所示。

(1) 特征提取：特征提取作为基于代价体的立体匹配算法的第一步，提取的特征会直接用于后续的步骤，影响后续步骤的精度与效率。通常该步由一个特征提取网络完成，该网络对输入的左右图像进行共享权重的特征提取，分别输出左右图像的高维特征信息。

(2) 代价体构建：经过特征提取后，需要将左右特征进行融合，模拟传统匹配算法中计算匹配代价的过程，但这里并没有直接计算代价，而是将包含代价信息的特征进行了融合，可以通过拼接也可以通过相似度计算方式进行左右逐像素的特征融合，构建一个形如 $D \times C \times H \times W$ 的四维代价体。该代价体包含左右图像的结构信息，为后续提取信息，计算视差做准备。

(3) 视差回归：在构建代价体过后使用三维卷积网络对其进行结构信息的提取与匹配代价的计算，最后获取一个 $D \times 1 \times H \times W$ 的代价体再进行回归计算，获得视差。




图 2.6 基于代价体构建的立体匹配

Figure 2.6 volume based stereo matching

2.3 深度学习相关理论

近年来，深度学习一直是学术界的研究重点，在工业界当中也得到了广泛的应用。在本研究中，除了计算机视觉相关技术外深度学习的技术也是重点研究内容。本节主要介绍本文所用到的一些深度学习相关知识。

2.3.1 卷积神经网络

在基于深度学习的计算机视觉领域当中，卷积神经网络有着举足轻重的地位，它被广泛地应用于图像分类、目标检测、图像分割等领域。卷积神经网络根据不同的任务需要有不同的网络架构，但都由以下四个基本结构组成：卷积层、池化层、全连接层、激活函数。

(1) 卷积层：卷积层是卷积神经网络的核心部件，主要起到对输入的图像/特征进行卷积计算，使用特征检测器（卷积核）在图像上进行特征的检测与提取，通过将卷积核与图像对应位置进行点积生成特征图。卷积的计算过程示意图如图2.7所示。




图 2.7 卷积操作

Figure 2.7 Convolution

(2) 池化层：在卷积神经网络的研究中，往往会受到硬件性能的制约，需要将通过卷积的获得的丰富特征进行降维或者降低分辨率，这就需要池化操作对特征图进行操作，用来降低后续操作的参数量。同时研究还发现引入池化操作可以引入随机性，加快卷积神经网络的收敛速度。池化操作2.8所示：目前常用的池化操作是平均池化与最大化池化。




图 2.8 池化操作

Figure 2.8 Pooling layer

(3) 激活函数：卷积神经网络的卷积层和池化层能够很好的进行线性拟合，但现实很多时候需要进行非线性的拟合来增加网络的表达能力，这就需要非线性的激活函数。常见的激活函数包括 ReLU (Rectified Linear Unit)、Sigmoid 和 Tanh 等。根据不同的应用场景可以选择不同的激活函数能够提高网络模型的精度。

(4) 全连接层：全连接层将每个神经元与前一层的所有神经元相连，综合所有特征。全连接层通常出现在神经网络的隐藏层和输出层中，是神经网络中最基本的结构之一。在基于卷积神经网络中的图像识别，图像分类等任务中，在经过多个卷积层和池化层后，需要学习和捕捉不同特征之间的复杂关系，进行特征的映射，一来可以映射到输出，二来可以进一步提高神经网络的表达能力。

2.3.2 扩大感受野的方法

在卷积神经网络中，每个卷积核（神经元）都有一个感受野，用来表示该神经元对输入数据的感知范围或者影响范围。在卷积神经网络当中，为了让网络能够更好地理解输入数据的上下文信息 (context)，捕捉更加丰富完整的全局特征和长距离依赖关系，从而提高模型的性能和泛化能力，有时需要扩大卷积的感受野。而目前改变卷积神经网络的感受野有三种方式：加深卷积神经网络的深度；直接扩大卷积核；空洞卷积 (Dilated Convolution)。

(1) 网络的加深：在卷积神经网络当中，随着卷积层和池化层的堆叠，顶层卷积核的感受野会逐渐增大，其示意图如图2.9所示。越上层的卷积层，由于下层的特征通道每一个元素是更下层的特征的融合特征，因此同样的位置能够感受到底层卷积更广的区域。感受野的大小随着网络深度之间的关系如公式 (2-3) 所示。公式中的 k' 为等效卷积核大小，其计算方式在后文当中的空洞卷积有讲解， $S_i = \prod_{i=1}^i Stride_i$ 为之前层所有步长 (stride) 的乘积，这种方法虽然能够增大网络的感受野，但是需要成倍地引入参数量，会使模型过于庞大，降低了模型的效率和性能。




图 2.9 卷积的堆叠

Figure 2.9 Stack convolution

$$RF_{i+1} = RF_i + (k' - 1) \times S_i \quad (2-3)$$

$$k' = k + (k - 1) \times (d - 1) \quad (2-4)$$

(2) 卷积核的扩大：另一种直观扩大感受野的方式就是直接扩大卷积核，对于单层卷积来说，卷积核的大小就是感受野的大小，因此可以直接扩大卷积核的尺寸来提高神经元的感受范围。但该方法同样会引入大量的参数，降低模型的效率与性能。

(3) 空洞卷积：空洞卷积是一种特殊的卷积方式，它将卷积核扩大再打上空洞，以此来扩大神经元的感受野，提高网络对全局信息的感知能力。其扩大感受野的方式如图2.10所示。该方法在扩大卷积核的同时并不会引入更多的参数，是一种成本较低的扩大感受野的方式。目前很多的网络当中都通过引入空洞卷积来增大感受野，并且取得了不错的成果^[73-74]。在本文的研究当中，也是通过引入空洞卷积来实现多尺度的空间注意力模块。




图 2.10 空洞卷积

Figure 2.10 Dilated convolution

2.3.3 基于卷积的注意力模块

基于卷积的注意力是一种结合了卷积神经网络和注意力机制的深度学习模块。注意力机制是一种模拟人类认知过程，让模型在处理图片或者特征时更加关注信息丰富部分的技术，其主要是通过不同区域的重要程度来动态地分配权重以提高模型的性能和泛化能力。以下是基于卷积的注意力模块的一般工作流程：

- 1. 卷积特征提取：**首先，通过卷积神经网络对输入数据进行特征提取，得到一系列特征图。
- 2. 计算注意力权重：**在每个特征图上应用注意力机制，计算每个位置的注意力权重，以确定哪些特征是最重要的或需要更多关注的。

3. **加权特征融合**: 根据计算得到的注意力权重, 将不同位置的特征进行加权融合, 以产生具有更加关注重要部分的特征表示。

目前, 常用的两种基于卷积的注意力模块主要包含 SENet^[75] 和 CBAM^[76]。SENet 中, 在获取了特征图过后, 学习每一个通道的特征图的重要程度, 然后动态调整它们的权重, 使网络能够更好地关注重要的特征。而 CBAM 在 SENet 的基础上补充了空间注意力, 在每一个特征通道内也计算注意力, 使模型能够更加关注特征的重要区域。本文所采用的注意力模块便是在 CBAM 的基础上进行创新与修改的。

2.3.3.1 通道注意力

在通道注意力当中, 需要对每一个通道计算注意力权重, 也即需要考虑每一个特征图中所有的像素位置, 全连接网络本是一种不错的选择, 但由于对所有特征图施以全连接网络会使参数量急剧上升, 有点得不偿失。而 SENet 和 CBAM 中使用的方法是先对特征图使用全局的池化操作, 将特征的尺寸降下来后再使用全连接神经网络进行进一步的注意力预测。通道注意力的一般计算方式如图2.11所示。其中的池化操作, 根据任务的不同可以选择全局平均池化和全局最大化池化, 也可两个都使用。




图 2.11 通道注意力

Figure 2.11 Channel attention

2.3.3.2 空间注意力

空间注意力的主要目标是在特征图内找到重点的区域, 因此它首先要将各个通道的特征进行融合, 再对融合过后的特征进行重点区域的确定。在 CBAM 当中首先使用了局部的池化操作对特征图进行了非线性计算, 然后将两种不同池化操作后的特征图进行拼接再进行卷积层的计算, 最后输出只包含一个通道的特征经过 sigmoid 激活函数获得注意力权重。如图2.12所示。

2.3.4 扩散模型

扩散模型是基于马尔科夫链的一种生成模型, 通过一个迭代逐步去噪的过程将正态分布的噪声生成为一个特定数据分布内的图像。扩散模型是目前的研究热点之一, 在图




图 2.12 空间注意力

Figure 2.12 Spatial attention

像生成和图像超分辨领域发挥了重要作用。本研究第五章将展示，经过一系列修改，扩散模型也可以用于散斑投影立体匹配当中的去除散斑图像的离焦当中。这一小节主要介绍扩散模型的基本原理。

2.3.4.1 扩散模型原理

扩散模型分为正向与逆向两个过程。其正向过程是逐渐给图像添加噪声最终使其成为正态分布的高斯噪声。其逐渐添加噪声的过程如公式 (2-5) 所示：

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_t \quad (2-5)$$

其中噪声的添加比例 α 是随噪声添加步数 $t \in [1, T]$ 变化的超参数，一般随着步数的增加逐渐缩小，使得 $\lim_{t \rightarrow T} \alpha_t = 0$ ，而 ε_t 是所添加的高斯噪声，其分布为 $\mathcal{N}(0, 1)$ 。该过程用分布的方式表示为 (2-6)，同时利用马尔科夫链可以快速地求得公式 (2-7)：

$$p(x_t | x_{t-1}) = \mathcal{N}(x_t | \sqrt{\alpha_t}x_{t-1}, \sqrt{1 - \alpha_t}) \quad (2-6)$$

$$p(x_t | x_0) = \mathcal{N}(x_t | \sqrt{\bar{\alpha}_t}x_0, \sqrt{1 - \bar{\alpha}_t}) \quad (2-7)$$

其中 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ，利用公式 (2-7) 就可以在正向过程当中，只需要一次计算，即可知道进行 t 步加噪后的 x_t 的分布。在逆向过程当中，由于如何去噪获取加噪声之前的图片 x_{t-1} 的过程 $p(x_{t-1} | x_t)$ 无法直接获得，在 DDPM^[77] 中，作者使用了贝叶斯公式，结合公式 (2-6) 和 (2-7) 得到了公式 (2-8)：

$$p(x_{t-1} | x_t, x_0) = \mathcal{N}\left(x_{t-1} | \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t + \frac{\sqrt{\alpha_{t-1}}(1 - \alpha_t)}{1 - \bar{\alpha}_t}x_0, \frac{(1 - \bar{\alpha}_{t-1})(1 - \alpha_t)}{1 - \bar{\alpha}_t}\right) \quad (2-8)$$

由于 x_0 与 x_t 的关系已知可以表示为公式 (2-9)，将其带入公式 (2-8) 中可以得到公式 (2-10)。使用公式 (2-10)，就可以进行逆向的去噪过程，一步步还原 x_0 了。但在真实实验环境中，很难直接获取到添加到图片上的噪声 $\varepsilon(x_t, t)$ ，所以只能训练一个神经网络 $\varepsilon_\theta(x_t, t)$ 来模拟这个噪声 $\varepsilon(x_t, t)$ ，然后将网络预测的噪声作为真值的噪声进行去除，就可以完成逆向的过程，从 $x_T \sim \mathcal{N}(0, 1)$ 生成一张特定分布内的图片 x_0 了。

$$x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}(x_t - \sqrt{1 - \bar{\alpha}_t}\varepsilon(x_t, t)) \quad (2-9)$$

$$p(x_{t-1} | x_t) = \mathcal{N}\left(\frac{1}{\sqrt{\alpha_t}}(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}}\varepsilon(x_t, t)), \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}(1 - \alpha_t)\right) \quad (2-10)$$

扩散模型的去噪公式 (2-10) 可以简化为公式 (2-11)，应用该公式，即可将一个正态分布的高斯噪声生成一张特定领域的图片。

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \sigma_\theta(x_t, t)) \quad (2-11)$$

公式中的 μ 和 σ 是分布 x_{t-1} 的均值与方差，其中方差 σ 是可以进行自由选择的，方差与正向过程的单步方差对齐或是与逆向过程的单步噪声方差对齐，最终生成图片的质量相差不大。 θ 则表示扩散模型中用于预测噪声的网络模型的参数。其训练的目标就是网络模型根据输入的上一步图片 x_t 和对应的步数 t 让 $\varepsilon_\theta(x_t, t)$ 与 $\varepsilon(x_t, t)$ 足够相近即可。

2.3.4.2 条件扩散模型

在本研究当中，为了进行散斑图案的去模糊，需要对扩散模型生成图片的过程进行“指导”，使生成的图片仍然能够保持原本的结构信息，不破坏立体匹配当中需要的信息。这便需要使用到条件扩散模型技术，其中的条件可以是文本、图像等信息，使用这些条件，可以用于指导模型生成与输入条件相关的样本。在扩散模型中引入条件的方式有两种，按照条件的引入时间分为两类：事后修改 (Classifier-Guidance diffusion) 与事前修改 (Classifier-Free diffusion)。值得一提的是，由于本文研究的数据集的特殊性，因此选择了需要进行重新训练，但是实现更简单高效的事前修改的方案。

(1) 事前修改条件扩散模型：

在条件扩散模型当中，可以在训练时将条件引入到扩散模型当中，将公式 (2-11) 所示的逆向过程变更为 $p_\theta(x_{t-1} | x_t, y)$ 其中 y 即是需要引入的条件。在条件扩散模型当中最直接也是简单的方式就是将逆向过程当中预测噪声的模型 $\varepsilon_\theta(x_t, t)$ 修改为 $\varepsilon_\theta(x_t, t, y)$ ，在训练时即将条件引入控制图像的生成过程。

(2) 事后修改条件扩散模型：

由于直接进行事前修改的条件扩散模型需要从零开始进行训练，需要耗费大量的成本，OpenAI 团队就提出了一种在现有训练好的扩散模型的基础上构建一个指导网络实现对扩散模型的控制^[77]。该条件扩散模型可用公式 (2-12) 进行表示。式中 Z 为一个常数， $p_\theta(x_{t-1}|x_t)$ 代表已经训练好的无条件扩散模型，而目前只需要构建一个网络 ϕ 预测 $p_\phi(y|x_{t-1})$ 即可。其原理可用 score function 的公式 (2-15) 所示。式中的 $\nabla \log p(x_t)$ 为无条件扩散模型的梯度， $\nabla \log p(y|x_t)$ 为分类器的梯度。从式中就可以看出，条件扩散模型只需要额外添加一个分类器的梯度来引导扩散模型生成图片即可。

$$P_{\theta, \phi}(x_{t-1}|x_t, y) = Z * p_\theta(x_{t-1}|x_t)p_\phi(y|x_{t-1}) \quad (2-12)$$

$$\nabla \log p(x_t|y) = \nabla \log \left(\frac{p(x_t p(y|x_t))}{p(y)} \right) \quad (2-13)$$

$$= \nabla \log p(x_t) + \nabla \log p(y|x_t) - \nabla \log p(y) \quad (2-14)$$

$$= \nabla \log p(x_t) + \nabla \log p(y|x_t) \quad (2-15)$$

2.4 本章小结

本章主要介绍了本文研究所需要的一些理论基础。首先介绍了双目立体视觉相关的内容，包括双目视觉原理以及基于条纹、散斑投影的双目立体视觉技术。并介绍了投影仪的成像模型为后续散斑大小变化的模拟和散斑离焦的模拟打下基础。同时介绍了基于深度学习的立体匹配算法。最后介绍了在后续章节中需要用的深度学习相关理论。

第3章 数据集的构建

3.1 实验环境与数据获取

本研究的目的是构建对于散斑投影立体视觉的鲁棒深度学习网络，因此需要大量的基于散斑投影的双目数据。本文没有选择公开的立体匹配数据，首先，在笔者写论文时尚没有基于散斑投影的双目立体匹配的公开数据集；其次，本研究需要进行散斑大小的动态调整和进行散斑离焦程度的调整，也没有公开数据集有进行散斑大小和散斑不同程度离焦的模拟。因此本研究自行搭建了一套基于散斑投影的双目系统用于构建本文所需要的数据集。该双目系统获取数据的大致流程如图3.1所示。同时，由于真实捕捉数据时间与金钱成本较高，为了尽可能多地扩充数据集的数量，本文还采用了数字孪生技术，构建了一个虚拟的采集系统，进行同步的采集，保证数据的数量和多样性。




图 3.1 数据集构建流程

Figure 3.1 The construction of datasets

3.1.1 真实数据的获取

使用如表格3.1当中的硬件以及配套软件，本研究搭建了如图3.3中的（a）子图所示的采集系统。图中的投影仪向被测物体投射多帧结构光信息（3 帧散斑和 18 帧条纹图），投影仪每投射一张结构光图案，左右两个相机同时曝光获取左右视图。为了获取高精度的视差信息作为本研究的真值，投影仪投射了三种频率的条纹，然后使用多步相移法求得左右图像的绝对相位，接着使用相位匹配构建高精度的视差信息。其处理过程如图3.2所示。从图中可知，本研究所采用的三种频率的条纹的步数分别是 4，4，10；为了快速获取足够多的散斑编码数据，本文在投射散斑图案时，连续投射了三张不同的散斑

用于构建数据集。使用该采集系统，本文对具有弱纹理特性的人脸和无纹理的面具与石膏模型进行了拍摄，总共拍摄了 53 个人脸数据和 155 个面具（石膏）模型，为了加快数据的采集量，本文在每一个模型进行采集时，都一次性投射了三张不同的散斑图案。因此总共拍摄了 624 对的真实数据。其中 63 对用于测试，561 对用于训练。

表 3.1 采集系统环境
Table 3.1 Capture system

名称	型号	数量	生产厂商	配套软件
相机	MER-U3	2	大恒图像	Galaxy Viewer
镜头	MPW2	2	康标达	无
投影仪	DLP4500	1	德州仪器	DLP Controller
GPU	RTX3090	1	英伟达	Pytorch+Python
CPU	i7-11700K	1	英特尔	Windows10




图 3.2 立体匹配数据获取流程
Figure 3.2 GT disparity acquiring process

3.1.2 仿真数据的获取

众所周知，深度学习常常面临着从实际系统中获取数据的挑战。在本研究当中，需要对散斑大小和散斑的离焦进行量化的控制，在真实系统中较难实现精准的控制，较难实现对散斑大小和离焦程度量化的研究。但是在仿真系统内，投影仪和相机的各项

参数都可以进行量化的调整。因此,本文使用真实双目系统采集数据以外,笔者还使用Blender软件搭建了一套数字仿真采集系统。通过数字孪生技术,将真实系统的参数导入到软件中,实现了仿真系统与真实系统的高度接近,并且使用这两套系统同步采集训练数据。同时,在仿真系统中模拟了散斑大小和散斑离焦的情况,为更深入地探究散斑特性提供了便利。

本文构建仿真系统的流程如下图3.3所示,首先使用(a)中所示的圆点标靶进行左




图 3.3 仿真系统的构建

Figure 3.3 The construction of digital twin

右相机的标定,获得两个相机的内外参数,以此来确定两个虚拟相机当中的基本参数。图中(c)子图为真实系统中左相机的标定参数,(d)子图为虚拟相机的参数设置。接着,根据这些参数摆放虚拟相机并确定了相机之间的距离和夹角,然后根据投影仪和相

机之间的位置关系摆放投影仪，并参考 Wang 等人^[78]的点光源渲染节点设置方式，使用 Blender 内的点光源进行投影仪的模拟（如（e）子图所示），使投影出来的图案与真实系统相近。最后，将“被测物体”放置在相机的最佳成像位置进行拍摄，即可完成虚拟数据的获取。真实系统与仿真系统所获取的成像示例分别在（a）子图的右上角和（b）子图的左上角。值得一提的是，Blender 软件作为一款强大的三维建模和渲染工具，不仅可以构建逼真的虚拟场景，还可以通过 Python 脚本控制系统参数，实现系统的自动化控制和数据采集。这提供了一个高度灵活和精准的仿真平台，能够快速准确地获取各种散斑大小和离焦情况下的成像数据，为后续的数据分析和研究奠定了坚实基础。例如调整图（e）中的投射比例中的 x 参数即可实现对于投射比例的模拟，投射不同大小的散斑；改变投射图案当中的图片源即可实现投射不同的结构光图片；改变光源设置里面的 $radius$ 参数即可实现投影仪的离焦模拟等等。使用该仿真系统，在保持与真实系统相近系统参数的设定下，拍摄了 100 个三维人脸模型的不同数据。每个模型在拍摄时所投射的散斑与真实系统当中投射的散斑也相同，因此每个模型也都会投射 3 种不同的散斑。同时，为了进一步扩充数据集，本文还对每一个模型进行了 5 种角度的摆放，总共有 1500 ($100 \times 5 \times 3$) 对左右散斑视图参与立体匹配网络的训练当中。另外，为了进行测试数据的生成，本文还对另外 20 个模型进行 3 种不同的角度摆放的拍摄，获取了 180 ($20 \times 3 \times 3$) 对图像用于测试。

3.2 散斑尺寸变化与离焦的仿真

3.2.1 散斑尺寸变化数据集

使用上述提到的仿真采集系统，可以通过调整图3.3中的（e）子图的投影仪光源渲染节点中第一个映射节点中的 $x-scale$ 参数来模拟投影比的调整。这种模拟模仿了真实世界中投影仪的放置距离变化或投影仪投影比的变化导致投影到物体上的散斑特征大小的变化的情况。本文从 0.25 间隔 0.05 一直到 1.00，总共使用了 16 种不同的散斑投射比例。这些投影比例所投出来的散斑图片的大小示意图如图3.4所示。当改变 Blender 的合成器窗口中第一个映射节点的 $x-scale$ 时，投影的图片的高度和宽度将呈线性关系。例如，当投影比设置为 0.5 时，模式的宽度和高度将与投影比为 1.0 时观察到的尺寸相比减半。这些不同散斑大小下的成像比较如图 3.5 所示。在图 3.5 的黄色框中，展示了将面部模型鼻端周围的一个长宽 20 像素的区域进行二值化获得的二进制模式。随着投射比例的增大，投影到面部模型上的模式也会变大。在黄色框内，散斑模式从一个复杂且多变的编码（左上）转变为一个较大面积且减少随机性的编码（右下）。散斑的形状和大小都发生了变化。本文共采集了 49 个未用于生成立体匹配训练数据集的三维模型，每个模型下投射了 16 种不同的投射比的散斑，共 784 对图像。值得注意的是，这些拥有不同大小的散斑测试图像并未参与训练过程。训练图像全部来自相同投影比下的散斑投影。




图 3.4 投影比例与散斑大小示意图

Figure 3.4 Projection ratio and speckle size




图 3.5 不同尺寸散斑成像图

Figure 3.5 Images of different speckle sizes

3.2.2 散斑离焦数据集

在本研究当中，还需要对投影仪所投的散斑图案进行离焦的模拟。当被测物体没有在投影仪的最佳成像区间，会出现离焦进而导致照射到物体表面的散斑出现模糊，降低立体匹配的精度。在真实系统中，若改变物体摆放的位置，相机的成像也会受到影响，因此本文使用上述提到的仿真系统进行投影仪的离焦，可以实现仅对投影仪投射的图片产生离焦，而相机的对焦与被测物体的位置不发生改变。以此实现更好地量化投影仪离焦对于立体匹配的影响。在真实系统当中，当投影画面与透镜系统的距离发生改变，在原本成像平面的光线不能够汇聚，产生画面的模糊，而重新在一个新的成像平面汇聚形成清晰的投影画面。其原理可用图3.6所示。而通过修改图3.3中(e)子图中点光源部分的半径(radius)参数可以模拟投影画面在光轴上的偏移距离 Δx 。当发生投影画面的偏移，在原本的成像平面上所呈现的画面就是模糊的画面。使用该方式进行模拟，就可以保证系统当中的其他参数不用发生变化，包括相机的拍摄角度与对焦，以及物体的摆放位置，相机的成像仍然是清晰的，只是投射上去的散斑结构受到影响。可以用于讨论分析离焦对于立体匹配精度的影响。本文通过调整图3.3中(e)子图中的半径参数，对于




图 3.6 投影仪离焦

Figure 3.6 Defocus of projector

每一个模型，拍摄了 1 张聚焦的图片和 13 张不同离焦程度的图片。13 张投影仪离焦图片所对应的半径参数为从 0.2mm 到 2.6mm 的等差数列。其中 0.2mm 到 2.4mm 这些不同离焦程度下的成像示例如图3.7所示，从左上到右下的投影仪离焦程度逐渐增大。可以看到随着离焦程度的逐渐增大，投射到物体表面的散斑图案越来越模糊，直至失去最初设计的散斑结构信息。本文总共拍摄了 240 个不同的模型，每个模型有 5 种不同的姿态进行数据集扩充。因此总共拍摄了 16800 对图像，其中共有 15600 对离焦的图案，在所有拍摄的离焦图案当中有 13000 对用于训练，1300 对用于验证，剩下的 1300 对用于模型的测试。




图 3.7 散斑离焦投影成像

Figure 3.7 Images of speckle defocusing projection

3.3 数据集的汇总

在本研究当中，由于不同的任务会涉及到不同的数据集，为了后续表述的方便，分别用 $Data_r$ 、 $Data_b$ 、 $Data_s$ 、 $Data_f$ 表示真实系统拍摄的数据集、仿真系统种拍摄的数据集、具有不同散斑大小的数据集、以及具有不同离焦程度的数据集。各个数据集的数据量如表3.2所示。其中 $Data_r$ 、 $Data_b$ 用于训练基础的立体匹配网络。 $Data_s$ 用于测试本文所构建网络是否能够较好地提高对于散斑尺寸变化的鲁棒性。 $Data_f$ 用于训练本文扩散模型，提高立体匹配网络对于离焦散斑的鲁棒性。

表 3.2 数据集汇总

Table 3.2 All data sets

符号表示	特点	训练集	测试集	总计
$Data_r$	真实系统拍摄	561	63	624
$Data_b$	仿真系统拍摄	1500	180	1680
$Data_s$	不同散斑尺寸	0	784	784
$Data_f$	不同散斑离焦程度	13000	2600	15600

3.4 本章小结

本章讲述了本文所需要使用的数据采集方法以及构建仿真数据的方式，并介绍了本文所使用的各个数据集的测试与训练集的具体数量。

第4章 基于多尺度空间通道注意力的立体匹配算法

4.1 引言

在单次散斑投影轮廓测量(SSPP)中,由于诸如视角变化、被测对象复杂表面调制和不同的投影比例等变化,投影的散斑不可避免地会发生形状和大小的变化。这些变化引入了随机性和不可预测性到散斑特征中,导致错误或遗漏的特征提取,进而降低了在被测表面上的三维重建精度。本研究旨在探索鲁棒的单帧散斑弱纹理表面的三维重建,因此本章主要讨论散斑大小变化与特征提取之间的关系,并从网络设计的角度着手解决这个问题。在不扩充散斑立体匹配网络训练数据集的情况下,利用散斑大小变化与散斑特征变化之间的关系,设计合适的网络结构,使网络能够更加全面地提取各种不同大小和形状的散斑特征,进而获得更精确的三维重建结果,以此来提高立体匹配网络对于散斑大小变化的鲁棒性。本章分析了散斑大小与特征提取之间关系,构建了归一化多尺度空间和通道注意力模块(NMSCA)并融合了拼接代价体与相似性计算代价体的优势,创建了 NMSCANet,以较低的计算资源代价实现了多尺度散斑特征的提取和增强,能较大程度地提高网络对于散斑大小变化的鲁棒性。其中多尺度空间注意力(Multi-scale spatial attention)被用来增强对空间中复杂和多变的散斑特征的感知,从而实现了跨不同尺度的全面特征提取;通道注意力(Channel attention)也被用来选择性地突出每个图像中最重要和代表性的特征通道,从而增强了对高频率三维表面轮廓的检测能力。实验结果表明, NMSCANet 在测试集上的点云重建稳定性(*Std*)可以达到8倍以上,并且在测量标准球和平面时,与其他方法相比,点云最近邻的平均距离(*Mean dis*)(0.0614毫米 - 0.4066毫米)和点云最近点标准差(*Std*)(0.0768毫米 - 0.7367毫米)的变化范围最小。面对散斑大小的变化, NMSCANet 将视差匹配精度(*EPE*)提高了超过35%,同时将匹配误差(*N-PER*)降低了超过62%。消融研究和有效性实验共同证明,本文提出的模块和构建的网络在提高网络精度和对抗散斑变化方面取得了显著进展。

4.2 多尺度空间通道注意力网络的构建

这一小节主要介绍针对散斑大小发生变化时构建的网络结构。在左右图像对进行极线校正之后,基于卷积神经网络的立体匹配网络目前有三个步骤:特征提取、代价体构建和视差回归。特征提取是这三个步骤中的第一步,具有重要意义。特征提取的质量直接影响后续代价体的质量,并进一步决定了后续视差回归的效率。本节首先讨论散斑尺寸变化与特征提取之间的关系,同时根据该关系设计了规划多尺度空间通道注意力模块(NMSCA)来提高匹配的精确度与稳定性。本文将 NMSCA 模块引入到基于二维卷积的特征提取模块中,在空间上对提取的特征进行多尺度注意力计算,以便提取的特征

可以关注不同尺寸的散斑。同时，通过使用通道注意力给不同通道施以不同的权重，使模型更加关注具有明显特征的通道。最终让立体匹配网络可以在准确性和鲁棒性上取得良好的表现。本章构建了一个结合归一化多尺度空间通道注意力和基于注意力拼接代价体的立体匹配网络^[40] 构建了 NMSCANet。其中基于注意力拼接代价体的立体匹配网络创新地结合了拼接代价体和相关代价体两种代价体的优点：它利用相关代价体的层级区块匹配结构构建代价体的空间注意力，然后利用这种注意力更新拼接代价体，该方法吸收了两种代价体构建方法的优点，从而在立体匹配中显著提高了准确性。尽管该方法在 Kitti^[79] 和 SceneFlow^[32] 等数据集上表现出良好的重建结果，但仍无法满足对单帧散斑三维形貌测量高精度和鲁棒性的要求。因此，本研究结合多尺度空间通道注意力的特征提取和基于注意力的拼接代价体构建了 NMSCANet，该网络的结构图如图4.1所示。其中多尺度空间注意力模块是一个特殊的卷积层，它以 $C \times H \times W$ 的特征图作为输入，并输出相同形状的特征图（ C 表示通道数， H 和 W




图 4.1 NMSCANet 的总体框架图

Figure 4.1 The framework of NMSCANet

分别表示高度和宽度)。这个过程类似于对特征的优化。因此，它可以适用于任何具有卷积特征提取模块的需要多尺度特征提取能力的网络。本研究在特征提取过程的每个二维卷积层之后添加了 NMSCA 模块。并且在使用各层级的特征在拼接之后，本研究也使用了 NMSCA 模块进行了特征的优化。

4.2.1 散斑尺寸与特征提取的关系

随着散斑大小的变化和三维物体对散斑模式的调制，散斑特征发生变化。本节主要探讨散斑大小变化与特征变化之间的关系。不管是传统的立体匹配还是基于深度学习

的方法，都需要对左右图像进行特征的提取。而常用的方法之一就是对区块进行滑动窗口的匹配。此外，基于卷积神经网络的深度学习中，浅层特征主要包括局部结构信息，这些信息也可以使用滑动窗口技术提取。为了了解随着散斑大小变化的特征变化规律，本研究对图3.5中不同大小散斑照射的图像进行了像素级滑动窗口检测。本文识别并计




图 4.2 散斑尺寸与特征关系示意图

Figure 4.2 Relationship of speckle size and feature extraction

算了两种窗口大小的局部特征数量，一种是长宽为 3 像素，另一种是长宽为 20 像素的窗口，进行逐像素的特征检测，统计每种散斑尺寸下能够提取到的特征种类数量。采样的示例和最终特征计数如图4.2所示。其中蓝色实线（长宽为 3 像素的特征）的结果表明，随着散斑的逐渐增大，在散斑立体匹配当中被光学传感器捕获的图像中局部 3×3 特征的总体数量逐渐减少，最大下降了。同时，由于一些三维形貌的调制，散斑发生形状的变化，较大的散斑（例如大小为 0.95 相比于 0.90）反而产生了更多的特征。散斑特征数量的大幅度变化对于立体匹配后续的步骤带来的极大的挑战：在基于数据驱动的深度学习中，如果在测试数据集中出现未在训练时见过的新特征，就难以实现对此特征的提取，而被测图像的不完整特征提取可能会导致匹配准确性下降。这一问题可以通过在训练集中添加包含该特征的数据来快速解决，但是如果在训练集中增加不同散斑大小照射下的数据，一方面会增加大量的成本，另一方面在现实情况下也不能在训练集里面包含所有不同大小的散斑，也就无法让网络通过训练集的方式学习到所有的散斑特征。因此，从特征提取的角度来看，通过更好的网络结构设计来帮助网络增强其对散斑变化的鲁棒性变得十分必要。此时，如果将特征检测窗口扩大到长宽为 20 像素，从图4.2中红

色虚线可以看出，散斑模式的数量受散斑大小的影响较小，从 0.25 的投射比例扩大到 1.00 的投射比例，散斑特征数量仅下降了 0.373%。由此可作为本研究网络设计的根据，尽可能通过模型设计让特征提取部分扩大感受野，让网络能够检测到足够多足够完整的散斑特征。

4.2.2 NMSCA 模块

这一节主要介绍 NMSCA 模块的结构细节。NMSCA 模块是一个轻量级的卷积注意力模块 (CBAM)^[43,76]，后来被 Chen 等人修改为多尺度空间注意力 (MSCA)^[74]，并应用于遥感图像中的对象识别。本文吸收了 MSCA 和 CBAM 的优点来构建 NMSCA。它主要包括两个部分：通道注意力模块和空间注意力模块。在通道注意力部分，不同于以往的研究方法^[43,76]只使用全局最大化池化或者全局平均池化中的一种进行注意力的计算，本研究同时引入了全局平均池化和全局最大池化，以确保通道注意力可以检测更准确的显著散斑特征通道。进一步，由于全局平均池化与全局最大池化最后的注意力值相差较大，进而使最后的通道注意力偏向于其中一方。为了减小这两种不同池化计算出的注意力权重差异，本研究还采用 Tanh 函数对输入特征进行归一化，将输入特征的范围限定到了 [-1,1]。至于空间注意力模块，本研究使用空洞卷积的方式来构建多尺度空间卷积，以此在特征提取当中检测不同大小和形状的散斑特征，然后将对于散斑立体匹配重要的散斑特征进行加强，最终提高散斑立体匹配网络对于散斑发生变化时的鲁棒性。同时，为了避免在训练过程中太多神经元的死亡，本研究还将传统卷积注意力模块中的 ReLU 也改为 Softplus。NMSCA 模块的示意图如图4.3所示。该模块的处理流程为：首先对输入的特征使用 Tanh 进行归一化和逐像素卷积 (pixel-wise convolution)，然后计算通道注意力和多尺度空间注意力，并分别在空间和通道上进行扩展。接着将两种注意力进行点乘并使用 Sigmoid 函数进行归一化获得最终的多尺度空间通道注意力，最后使用该注意力对归一化过后的输入特征进行提炼，便可获得输出特征。以下为更加详细的 NMSCA 模块处理过程。输入一个形为 $F^{C \times H \times W}$ 的特征图，并用 $Tanh$ 函数对其进行归一化，得到 $F_{norm}^{C \times H \times W}$ ；使用 NMSCA 模块计算一个与输入特征相同形状的注意力图 $A^{C \times H \times W}$ ；然后使用这个注意力图来优化输入特征，得到用于下游任务的新特征图 F_a 。整个过程的表达形式如下：

$$F_a = F_{norm}^{C \times H \times W} + F_{norm}^{C \times H \times W} \otimes A^{C \times H \times W} \quad (4-1)$$

其中注意力图 $A^{C \times H \times W}$ 来自于两个部分：一个是空间注意力 A_s ，另一个是通道注意力 A_c 。空间注意力和通道注意力的获取在后文中有详细的介绍。它们分别通过通道扩展和空间扩展到相同大小，然后进行点乘，最后通过 Sigmoid 激活函数得到 $A^{C \times H \times W}$ 。下面是该过程的表达形式，模块结构如图4.3所示。

$$A^{C \times H \times W} = Sigmoid(A_c \otimes A_s) \quad (4-2)$$




图 4.3 NMSCA 结构示意图

Figure 4.3 NMSCA module structure.

4.2.2.1 多尺度空间注意力模块

多尺度空间注意力模块的功能是提取特征图的空间注意力。在基于立体匹配的单帧散斑三维重建方法中，由于投影仪本身投射比例的变化导致投射出的散斑大小发生变化，同时散斑的大小和形状可能会随着物体三维形貌的调制而发生不规则的变化。这些都将导致一些散斑的结构信息在特征提取中丢失，从而影响匹配的准确性。而本研究所设计的多尺度空间注意力能够提取不同尺寸的散斑结构信息，并针对性地加强经历变形和大小变化的散斑结构信息，以避免后续处理中的特征丢失。为了实现多尺度空间注意力，本研究采用了空洞卷积^[73]来改变卷积的感受野，并检测不同形状和大小的散斑特征。对于归一化的特征图 F_{norm} ，本章分别使用扩张率为 1、2 和 3 的三个 3x3 卷积来获得不同尺度的空间注意力 A_{s1} 、 A_{s2} 、 A_{s3} 。然后将它们拼接起来，经过一个逐像素 1x1 卷积和 SoftPlus 函数的归一化，得到输入特征图的多尺度空间注意力 A_s 。该空间注意力的计算过程可用如下的公式（4-3）到公式（4-6）表示，也可参考图4.3中的空间注意力板块：

$$A_{s1} = SConv_1(SConv_1(F_{norm})) \quad (4-3)$$

$$A_{s2} = SConv_2(SConv_2(F_{norm})) \quad (4-4)$$

$$A_{s3} = SConv_3(SConv_3(F_{norm})) \quad (4-5)$$

$$A_s = \text{SoftPlus}(\text{Conv2d}^{1 \times 1}(\text{concat}(A_{s1}, A_{s2}, A_{s3}))) \quad (4-6)$$

其中 $SConv_n$ 表示经过一个空洞率为 n 的 3×3 卷积和一个 SoftPlus 激活函数的输出。

4.2.2.2 通道注意力模块

通道注意力用于计算特征通道之间的注意力的模块。与空间注意力不同，通道注意力关注的是各个特征通道之间的差异。网络的特征提取模块是在训练数据集中的所有图像对上进行训练的，特征提取模块理应能够提取整个训练数据集中存在的各种特征。而在进行测试时，一对图像往往只包含部分训练集中的特征，而被提取到的特征，会被组织到特征图的不同通道当中。由于卷积的特性，测试图像对中没有包含的属于训练集的特征仍会以一个较低的权重在对应的特征通道上进行占位。因此，对于整个的特征图，并不是所有通道都对当前的立体匹配图像对有贡献，而不同的通道所代表的特征重要程度也不一样。这也就需要通道注意力对各个特征通道计算注意力，然后进行不同程度的加强。保留下对于特定立体匹配图像对最重要的特征。

通道注意力的计算过程与空间注意力模块的过程类似，首先对输入特征进行归一化，得到 F_{norm} ，然后分别计算全局平均池化（AP）和全局最大池化（MP）。然后使用一个多层感知机（MLP）来获得平均通道注意力 A_a 和最大通道注意力 A_m 。最后，这两种注意力相加并平均，得到通道注意力 A_c 。通道注意力的计算过程如公式（4-7）到公式（4-9）所示，其网络结构图如4.3中顶部通道注意力所示：

$$A_a = \text{MLP}(\text{AP}(F_{norm})) \quad (4-7)$$

$$A_m = \text{MLP}(\text{MP}(F_{norm})) \quad (4-8)$$

$$A_c = (A_a + A_m) / 2 \quad (4-9)$$

其中 MLP 由两个基础线性变换和一个 SoftPlus 激活函数组成

4.2.3 损失函数

在 NMSCANet 中，本研究采用 smoothL1Loss 作为立体匹配的损失函数：

$$\text{smoothL1}(x, target) = \begin{cases} 0.5(x - target)^2, & (|x - target| < 0.5) \\ |x - target| - 0.5, & (|x - target| \geq 0.5) \end{cases} \quad (4-10)$$

其中， x 是预测的视差值， $target$ 是真实视差值。

4.3 实验结果与分析

这一节主要介绍了本研究设计的各种实验、数据集、实验配置以及评估指标。以定性和定量的方式分析 NMSCANet 在单帧散斑三维重建中的准确性和鲁棒性。此外，本章还与三个对比网络进行了比较。同时本章还进行消融实验来验证 NMSCA 模块中多尺度空间注意力和通道注意力的有效性。另外，本节还进行了泛化实验，研究 NMSCANet 在真实环境下的重建能力，来检验网络的泛化能力。最后，本章还设计了有效性实验来确认 NMSCANet 所取得的准确性和鲁棒性的改进不是来源于网络的加深和网络参数数量的提高，而是来自于优秀的深度学习网络结构设计。

4.3.1 数据集

在本章的研究当中，使用了3.3节当中使用真实系统拍摄的 $Data_r$ 与 $Data_b$ 用于训练以及测试立体匹配网络。这两个数据集当中的散斑大小是相同的，且各自数据集内也都是在相同大小散斑照射下拍摄的图片，只是会有不同的散斑模式。同时为了测试本章所提方法能否降低散斑大小变化带来的精度的影响，本章使用了具有 16 种不同散斑尺寸 $Data_s$ 进行测试。

4.3.2 对比网络

本研究选取了三个立体匹配网络作为对比模型。第一个是经典但有效的 PSMNet^[35]，它具有金字塔特征提取模块和一个沙漏式 3D 卷积回归模块。之所以选择它，是因为它具有类似于 NMSCANet 的强大的多尺度空间特征检测能力，可以评价两种不同的多尺度特征提取方式对于散斑立体匹配的适应程度。第二个网络是 ACVNet^[40]。它整合两种不同的代价体构建方法来优化代价体的构建方法，充分利用提取到的特征，在大场景的立体匹配任务中获得了不错的结果。然而，对于散斑立体匹配，该方法并没有考虑到不同散斑大小会带来特征的变化。引入该方法可以较好地呈现 NMSCANet 网络优势带来的精度和鲁棒性的提升。第三个网络是最近发布的 DCSMNet^[48]，它是笔者在做本研究时针对单帧散斑三维重建任务最新和最有效的立体匹配网络。与该网络对比可以讨论本文提出的方法对单帧散斑三维重建的适应程度。在对比实验中，本研究使用了 $Data_r$ 和 $Data_b$ 的训练集进行训练。笔者将每个图像水平切分成四等份（每份大小为 256 像素×1280 像素），然后将左右图像对应输入进行训练。在测试时，则将被测试的主体部分裁出（每张图片的大小为 688 像素×768 像素）。

在本研究的对比实验当中，各个网络训练的学习率（learning rate）设置为 0.001，训练周期（epoch）设置为 146，批量大小（batch size）设置为 3。训练损失函数为 SmoothL1。训练和测试环境为 Windows 10、Pytorch，使用的硬件是 Nvidia 的 3090GPU。

4.3.3 评价指标

本研究从视差和点云的角度评估所提立体匹配网络的匹配精准度会鲁棒性。在视差方面,本文选择了两个评估指标: N 像素误差率 (n pixel error rate, N - PER) 和端点误差 (end point error, EPE)。在点云方面,本文采用了两个评估指标: 平均最近邻距离 ($Mean\ dis$) 和最近邻距离标准差 (Std)。从数值上看,这些指标越小,视差预测的准确性越高,立体匹配网络对大小不同的散斑特征的鲁棒性也越强。具体来说,本研究利用 Std 作为评估指标来评估模型在面对不同的散斑大小时的稳定性。较小的 Std 表示在预测视差时立体匹配有更高的准确率。在单一的图像对中,由于被测模型复杂表面的调制,散斑大小和形状的变化是不可避免的。因此, Std 的降低表示立体匹配网络在各个不同区域都能够表现出相似的高质量匹配结果,也就是说在给定场景中面对不同散斑特征时表现出更强的稳定性。此外,在改变散斑大小时 Std 随之的变化范围 ΔStd 也可以作为评估模型重建稳定性的指标。对于不同的散斑大小, ΔStd 越小表示网络更稳定,而相反则证明网络受到散斑大小变化带来的影响较大。通过评估这些指标在散斑大小变化时的最小变化量,可以深入了解网络的对于散斑大小的鲁棒性。

$$N - PER = \frac{1}{n} \sum_{i=1}^n \left[(|pre_i - gt_i| > N) \& \left(\frac{|pre_i - gt_i|}{gt_i} \right) > thres_N \right] \quad (4-11)$$

$$EPE = \frac{1}{n} \sum_{i=1}^n |pre_i - gt_i| \quad (4-12)$$

$$Mean\ dis = \frac{1}{m} \sum_{i=1}^m dis(est_i, gt_i) \quad (4-13)$$

$$Std = \left[\frac{1}{m} \sum_{i=1}^m (distance(est_i, gt_i) - Mean\ dis)^2 \right]^{\frac{1}{2}} \quad (4-14)$$

公式 (4-11) 中, N 为误差像素的量,常用的有 0.5, 1 和 3, 而其中的阈值 $thres_N$ 也会因为 N 的变化发生改变。当 N 为 0.5、1 或 3 时, $thres_N$ 分别为 0.01、0.02 或 0.05。公式 (4-14) 中的 dis 表示重建点云中某个点与真值点云中最近邻点之间的欧氏距离。

4.3.4 对比实验

4.3.4.1 可视化实验

为了直观地验证本研究设计的网络结构在面对散斑大小变化时的有效性和稳定性,本文进行了对比实验,通过画出重建的点云图和它们的点云误差图来更加直观地进行对比。本文在 $Data_s$ 上进行了对比实验,获得在各种散斑大小下的网络匹配结果,并使用得到的视差图进行三维点云重建,本文选择了三种代表性的散斑大小,并将其排列在




图 4.4 人脸点云重建结果

Figure 4.4 3D Reconstruction Result of Human Face

图4.4中。这三种散斑大小对应的投影比分别为 0.35、0.7 和 1，代表小散斑、中等散斑和大散斑，其中 0.7 为在散斑立体匹配中较为常用到的散斑大小，也是本文训练集所采用的散斑大小，而 0.35 和 1 都是在 0.7 的基础上有较大程度的变化的散斑，因此选用这三种大小的散斑进行展示可以定性地对比不同散斑大小下网络的匹配结果精度。同时，本文还将各个网络对于该模型的匹配结果的 0.5 像素误差 (0.5 *PER*) 和端点距离 (*EPE*) 标注于图4.4对应点云重建结果下方，分别用蓝色和红色字体进行标出。此外，本文还使用条纹投影轮廓术来获得高精度视差图并进行三维点云重建作为真值点云。使用该真值点云，也就可以进一步计算每个网络匹配结果重建的点云与真值之间的平均最近点 (*Mean dis*) 和最近点距离标准差 (*Std*)。本文将各个网络匹配结果进行三维点云重建过后与真值点云计算最近邻距离，根据不同的距离给点云进行上色，对比各网络在不同区域的重建精度。计算结果和点云可视化如图4.5所示。

从图4.4和图4.5中重建的点云中可以清楚地看到，与其他三个网络相比，NMSCANet 的整体重建结果更加平滑、更完整、更细致。此外，当散斑大小被放大或缩小到较大程度时（散斑大小为 0.35 和 1 时），它仍然保持良好的重建结果，而其它网络的匹配精度有着明显的下降。同时从图4.5中还可以总结发现：当散斑大小发生变化时，NMSCANet 的低误差区域（图中偏向于绿色的部分），覆盖了更大的区域。当散斑大小放大或缩小时，三个对比网络的高误差区域（图中偏向于黄色的部分）占据了更大的区域，并且出现了明显的散斑状误差。这在一定程度上证明这些网络未能提取完整的散斑特征，当散斑大小和形状发生改变时，对比网络在某些识别不完整的散斑位置出现匹配的误差，进而导致三维重建点云中的散斑状误差。这证明了 NMSCANet 对散斑变化更具鲁棒性。




图 4.5 人脸点云误差图

Figure 4.5 The error of reconstructed human faces

4.3.4.2 量化实验

除了通过可视化重建结果以评估网络的优越性外，本文还通过计算三维重建点云与真值点云之间的 *Mean dis* 和 *Std* 来量化不同网络之间的匹配精度和鲁棒能力的差异。本文将 *Mean dis* 和 *Std* 标注在图4.5重建点云的下方，并分别使用蓝色和红色的字体进行区分，以便更好地阅读同时方便与可视化实验进行关联。从图中显示的指标来看，NMSCANet 在所有尺寸散斑的重建中具有最小的 *Mean dis* 和 *Std*。为了进一步确认每个网络在各个不同散斑尺寸下的端点误差和 N 像素误差，本文计算了各个网络在每一个散斑尺寸下的平均端点误差和 N 像素误差，并将其绘制成折线图，如图4.6所示。对于每种散斑大小，本研究有 49 对测试输入图像。本实验首先计算了每一对的 0.5PER、1PER、3PER 和 EPE，再根据不同的散斑尺寸计算了它们在不同散斑大小下的平均值。从图4.6中可以观察到，本文所提出的 NMSCANet 在所有大小的测试散斑下都实现了最佳的匹配结果。特别的，笔者从中选取出在散斑尺寸为 0.7 的匹配结果，将各个评价指标的具体数值列在表4.1中。结果表明，相比对比方法中最好的 ACVNet，本文所提模型的端点误差（EPE）降低了超过 35%，0.5PER、1PER 和 3PER 分别降低了超过 62%、65% 和 69%。然而，在执行效率方面，与 ACVNet(0.2895s) 相比，预测时间(0.3864s) 增加了 33%，但比经典的匹配算法 PSMNet(0.3954s) 稍快。

从图4.6(a)-(d) 可以得出结论，NMSCANet 在所有不同散斑尺寸下保持了最佳的预测结果。与此同时，随着散斑尺寸的变化（指标的最小值和最大值显示在 y 轴右侧），NMSCANet 的精准度变化最小，始终保持在一个最小的范围内，N 像素误差均在 15% 以下，端点误差也都保持在 3.16 像素以下。而各个对比网络当从立体匹配最佳散斑大小




图 4.6 不同散斑大小各模型对比结果示意图

Figure 4.6 Comparison results of models with different speckle sizes

表 4.1 0.7 散斑大小下的匹配结果

Table 4.1 Disparity comparison under speckle size 0.7

	$EPE(px)$	$0.5PER(\%)$	$1PER(\%)$	$3PER(\%)$	$Time(s)$
ACVNet	0.7617	6.47	4.59	2.51	0.2895
PSMNet	2.0221	8.76	6.14	3.85	0.3954
DCSM	8.5982	12.51	9.56	7.41	0.3267
NMSCANet	0.4897	2.45	1.43	0.77	0.3864

区间 $[0.65, 0.75]$ 向两侧进行尺寸的变化时, 网络的匹配结果都会呈现出较大的误差, 精准度出现大幅度地下降。再结合图 4.5 中点云的 $Mean\ dis$ 和 Std 的数据, 可以得出这样的结论, 当散斑尺寸出现较大程度的变化时, 本文所提出的 NMSCANet 网络将重建点云的 $Mean\ dis$ 减少了超过 93%, 并将整体点云重建的稳定性 (从 Std 上看) 提高了 8 倍以上。

此外, 为了提供更标准的匹配精度和鲁棒性的定量分析, 本文使用标准球体 (直径: 100 mm) 和平面 (尺寸: 100 mm × 80 mm) 进行了更进一步的对比实验。球体和平面与成像平面的平面距离为 862 mm。所有对比网络的在 16 种散斑尺寸下的对比结果如图 4.7 所示。从这些子图中可以清楚地看出, 本文所提的 NMSCANet (在图中用红色圆圈标记) 始终表现出最好的匹配结果, 最低的匹配误差。为了更详细地比较, 本文选择了四种不同尺寸的散斑 (0.25、0.45、0.65、0.85) 下的匹配结果来重建点云。




图 4.7 不同模型在球体和平面上的比较折线图

Figure 4.7 Comparision results of different models on the sphere and planer.




图 4.8 球体和平面的点云结果

Figure 4.8 The point cloud of sphere and planer

其重建结果如图4.8所示,本文可视化了重建点云与真值点云之间的最近邻距离,并计算了点云的 *Mean dis* 和 *Std*, 将其标注在了图中的重建点云下方, 分别用蓝色和红色的字体进行表示, 以比较不同网络在这些散斑尺寸下的整体重建精度。最终可以得出结论, 本文方法重建的点云结果最好, 在 *Mean dis* (0.0614 mm - 0.4066 mm) 和 *Std* (0.0768 mm - 0.7367 mm) 上变化范围最小, 本文所提的方法对于散斑大小的变化是所有对比方法中最鲁棒的。

4.3.5 泛化实验

由于本文提出的网络的训练集大部分为仿真数据集, 而只有小部分为真实拍摄的数据, 为了验证网络在真实场景中的推理能力, 本文还对在真实场景中捕获的数据集 *data_r* 的测试集进行了点云重建和与真值点云的最近邻距离评估。结果展示在图4.9和图4.10中。从图中可以看出, NMSCANet 具有最平滑、最接近 GT 的全局重建结果。其低误差区域(绿色区域)覆盖面积最大且更完整。此外, 从图4.9中放大的区域可以清晰地看出, 本文所提的 NMSCANet 在眼睛和睫毛等小的突变区域具有最佳的点云重建能力, 其整体的 *Mean dis* 和 *Std* 相较于其他的网络也更加小, 这也意味着 NMSCANet 对于三维物体表面的调制引起的散斑形状变化更具有鲁棒性。




图 4.9 面具三维重建结果

Figure 4.9 Reconstruction of mask




图 4.10 真实人脸重建结果

Figure 4.10 Reconstruction of real human face

4.3.6 消融实验

为了评估本文提出的 NMSCA 模块中各个组件的有效性，进行了消融实验。本文分别从 NMSCANet 中移除多尺度空间注意力模块和通道注意力模块，构建了 Net A 和 Net B。对比它们与 ACVNet 和 NMSCANet 的立体匹配性能。这四个网络所包含的网络模块如表 4.2 所示。实验结果如图 4.11 所示。从图 4.11 中可以看出，本文提出的方法显著提高

表 4.2 消融实验模型设置

Table 4.2 Ablation experiment models settings

	NMSCANet	Net A	Net B	ACVNet
Multi-Scale Spatial Attention	✓	×	✓	×
Channel Attention	✓	✓	×	×

了立体匹配网络的匹配精度。无论是使用多尺度空间注意力还是通道注意力，网络对于散斑尺寸变化的鲁棒性都得到了极大的提升。而当两者同时发挥作用时，网络的整体精度达到了最高点。令人惊讶的是，通道注意力对于网络在散斑变化情况下的性能提升与多尺度空间注意力对于网络面对不同尺寸散斑的稳定性提升不相上下。究其原因，在多个卷积层的特征提取过程中，不同通道被训练以捕获不同的散斑特征。通过引入通道注

意力, Net A 能够优化特征通道并选择最适合每个图像对的少量通道,从而获得更准确的特征表示。这种优化导致了 Net A 的全局匹配精度的提高。为了进一步探讨多尺度空




图 4.11 消融实验的对比折线图

Figure 4.11 Comparison plots of ablation experiments.

间注意力和通道注意力在立体匹配的特征提取当中的作用,本研究进一步对点云重建结果进行了比较分析,如图4.12所示。

本文选择了散斑大小等间隔变化的 8 张散斑照射图片进行三维点云重建。图中的每一行代表了不同散斑尺寸照射下各个网络模型的重建结果。通过比较第二行和第三行,具有通道注意机制的 Net A 确实有显著改善了匹配结果。从整体上看,与 Net B 相比,Net A 实现了更高的重建精度。但可以观察到,即使 Net A 在平均距离和标准差方面表现更佳,从视觉上看,在散斑照明从 0.3 到 0.5 和 0.8 到 1 的范围内,其点云重建结果倾向于具有更多类似散斑的突起。相反地,具有检测多尺度散斑特征能力的 Net B 可以实现更好的局部匹配,在点云重建结果中呈现出更平滑的点云重建。第四行展示了 NMSCANet 的重建结果融合了 Net A 和 Net B 的优点。它既实现了 Net A 的较高的重建精度,又实现了 Net B 更加平滑和准确的点云重建效果。

总之,通道注意力和多尺度空间注意力都对 NMSCANet 在视差精度方面的性能提升做出了贡献,它们同等重要。通道注意力能够优化特征通道,显著提高全局精度。另一方面,多尺度空间注意力关注局部散斑特征的变化,导致点云重建结果更加平滑。通过结合通道注意力和多尺度空间注意力,本文提出的网络在全局上实现了高精度,并在局部产生了良好的重建结果。



图 4.12 消融实验中点云重建结果

Figure 4.12 The reconstruction result of ablation experiment

4.3.7 有效性实验

考虑到本文提出的 NMSCA 模块不可避免地增加了模型的参数数量，和模型的深度。本文还设计了有效性实验来验证 NMSCANet 的更好的立体匹配结果和针对散斑大小变化更好的鲁棒性是来自于优秀的网络模块设计，而不是模型的加深或参数量的增加。笔者在 ACVNet 的原始特征提取部分引入了两个基本模块（Basic module）^[80]，使其参数数量增多，模型深度加深，最终模型参数数量略微超过 NMSCANet。本文将这个加深后的网络表示为 ACVDeepNet。在 $data_s$ 上，ACVNet、NMSCANet 和 ACVDeepNet 的对比结果如表4.3所示。

表 4.3 有效性实验结果

Table 4.3 Validity experiments results

	Parameter Num.	Mean dis(mm)	Std(mm)	EPE	0.5PER(%)
ACVNet	6230944	0.1973	0.2037	0.2912	9.75
ACVDeep	6342048	0.1710	0.1856	0.2847	7.13
NMSCANet	6319705	0.1339	0.1402	0.1997	3.91

从表4.3中可以得出结论，NMSCANet 与 ACVDeep 具有几乎相同数量的参数，前者

甚至略少 30,000 个参数。然而, NMSCANet 在点云和视差评估指标上都优于 ACVDDeep。显然, NMSCANet 的卓越匹配性能并不源自网络参数的增加或网络深度的提高, 而是来自更好的网络模块设计。

4.4 本章小结

综上所述, 本章探究了单帧散斑投影轮廓术中散斑大小变化与特征提取之间的关系。通过在网络设计中引入 NMSCA 模块, 解决了由散斑大小和形状变化导致的精度下降问题。NMSCA 模块包含了空间注意力和通道注意力两部分。在空间注意力方面, 本文设计的多尺度空间注意力能够有效提取和增强不同形状和大小的散斑特征, 以防止在后续处理中丢失局部结构信息。而在通道注意力方面, NMSCA 能够为每一对输入图像选择最合适的散斑特征, 为每一对立体匹配图像对进行不同程度的通道增强, 进一步帮助模型达到高的全局匹配精度。本章将 NMSCANet 与几种现有的优秀立体匹配网络进行了比较, 结果显示, 与其他网络相比, 视差 $N-PER$ 降低了 62%, 并且重建的点云的最近点距离的稳定性 (从 Std 来看) 提高了 8 倍以上。消融实验和有效性实验也证明了本文提出方法的有效性。泛化实验证明了 NMSCANet 有较强的泛化能力, 能够应用到实际的三维重建任务当中。

第5章 基于扩散模型的投影散斑去离焦算法

5.1 引言

在散斑投影轮廓术中,当被测物体与结构光双目系统的距离发生变化时,不仅散斑的大小和形状会随之改变,导致立体匹配精度下降,还有投射到物体表面的散斑特征清晰程度也将随之变化,进而影响立体匹配网络的匹配精度。如果投影仪在投射散斑时由于焦平面选择错误或者物体的深度超越了投影仪的成像对焦区间,投影到物体上的散斑将会呈现模糊状态,这种模糊将在一定程度上改变散斑特征,进而导致立体匹配网络的精度下降。本章所采用的方法则是利用最新的研究热点——扩散模型,来解决这一投影仪离焦的问题。通过扩散模型,可以对投射到物体上的离焦散斑进行重构,从而恢复其原有的散斑特征。这种方法不仅可以对全局的投影仪离焦散斑进行重构,还可以对局部离焦的散斑特征进行重构。同时,本章采用离焦的图片作为扩散模型的条件,在“指导”去离焦过程时,能够同时去除不同程度的离焦模糊,使得扩散模型的输出能够稳定地用于后续的立体匹配算法。

5.2 去离焦网络的构建

在基于扩散模型的图片生成当中,关键是逐步对带噪声图片进行噪声的去除,其过程可用公式(2-11)表示。而在本研究当中,扩散模型的应用并非简单的图片生成,更要根据输入的离焦的图片 y 进行图片的生成,让生成的图片 x_0 是 y 所对应的聚焦的图片。该图片的生成过程可以表示为 $p_\theta(x_0 | x_t, y)$ 。结合第二章中介绍的从 t 步带噪声图像预测 $t-1$ 步带噪声图像的过程 $p(x_{t-1} | x_t)$ (公式(2-10)),引入离焦图片 y 到该去噪过程当中,使图像的去噪过程有离焦图片 y 的指导。这一过程可以用公式(5-1)表示。公式中 $\varepsilon_\theta(x_t, t, y)$ 表示噪声预测网络(θ) 在离焦图片(y)和步数(t)指导下预测出的应该对带噪图片(x_t)应该减去的噪声(ε)。将 x_t 减去预测的噪声即可得到 x_{t-1} 。重复该步骤,就可以获得在条件 y 指导下生成的无离焦图片 x_0 。因此,其中最重要的就是这个噪声预测网络 $\varepsilon_\theta(x_t, t, y)$ 。本节主要集中于噪声网络的构建,以及介绍使用该网络进行训练以及离焦的过程。

$$p_\theta(x_{t-1} | x_t, y) = \mathcal{N}\left(\frac{1}{\sqrt{\alpha_t}}(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}}\varepsilon_\theta(x_t, t, y)), \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}(1 - \alpha_t)\right) \quad (5-1)$$

5.2.1 噪声预测网络

本文所构建的噪声预测网络如图5.1所示。整体是一个 UNet 架构,包含了编码器,解码器,以及连接两部分的瓶颈块(bottleneck block)。在本章当中,整个噪声预测过




图 5.1 噪声预测网络

Figure 5.1 The noise prediction network

程都需要在离焦条件 y 的指导下进行，为了更好地保留条件 y 中的特征信息，使其能够进行更深层次网络中的传播，在本文所构建的噪声预测网络当中使用了残差连接块（ResNet block）作为基本单元。该网络总共有四个层级，随着层级的加深特征的尺寸逐渐减小，但是特征通道数成倍递增，以更好平衡网络性能与参数量。在该网络中，没有采用常用的池化操作来进行下采样，而是使用一个步长为 2 的二维卷积层完成，这样子可以尽可能多地保留层级之间地特征传递。每次下采样后特征的长宽都会变为原来的 $\frac{1}{2}$ ；而在上采样块当中，包含了一个基于最近邻的上采样层以及一个二维卷积层，上采样块用于实现对更深层次的特征进行解码，同时逐渐恢复空间信息，使特征尺寸变为原来的 2 倍。同时为了进一步提高网络的特征表达能力以及实现对 y 的多尺度区域关注，实现对不同区域散斑图案进行不同程度的去离焦操作，本文在第二层和第四层的残差网络块引入了第四章中提出的归一化多尺度空间通道注意力模块（如图4.3所示）。网络中的残差网络块的结构如图5.2所示。首先对输入的特征进行组归一化（Group Norm）与二维




图 5.2 残差网络块

Figure 5.2 The ResNet block

卷积然后与输入的当前去噪步数 t 相加进行第二次组归一化，归一化后进入 Dropout 层与二维卷积层。再将得到的特征与输入特征进行残差连接即可得到输出的特征。其中的 Dropout 层可以随机失活部分神经元的输出，将对应的输出置为 0，以此减少神经网络

的复杂度并提高网络的泛化能力。

5.2.2 正向扩散过程

为了让上述网络能够进行噪声的预测,需要进行扩散模型的正向学习过程。也就是对没有离焦的图片逐渐添加噪声,使其最后成为高斯噪声,然后让上述的网络在该扩散过程当中去学习添加到图片当中的噪声模式。本文所采用的扩散核与 DDPM^[77] 中相同,都是高斯噪声。其训练噪声预测模型的正向扩散过程的表示为算法 1。利用公式 (2-7) 可以一步求得未离焦图片 x_0 添加 t 步噪声过后的图片 x_t , 再使用公式 (2-6) 可以获得从 x_{t-1} 到 x_t 所添加的噪声 ε_t 。将此时的步数 t 、添加噪声后的图片 x_t 以及聚焦图片 x_0 输入到上述的噪声预测网络当中,预测此时被添加到 x_{t-1} 上的噪声 $\varepsilon_{\theta t}$, 再使用真实添加上去的噪声 ε_t 对网络进行损失计算与梯度回归即可让网络逐渐学习到正向添加的噪声。当网络学习到噪声添加过程过后,再对一个高斯噪声采用逆向过程即可获得清晰的图片 x_0 。

算法 1 带条件 y 的正向扩散过程

```

1: repeat
2:    $x_0, y \leftarrow \text{Dataloader}(x_0, y)$ 
3:    $t \leftarrow \text{Uniform}(\{1, 2, 3, \dots, T\})$ 
4:    $x_t \leftarrow p(x_t | x_0) = \mathcal{N}(\sqrt{\alpha_t}x_0, \sqrt{1 - \alpha_t})$ 
5:    $\varepsilon_t \leftarrow \mathcal{N}(0, I)$ 
6:    $\varepsilon_{\theta t} \leftarrow \varepsilon_{\theta}(x_t, t, y)$  {使用噪声预测模型预测当前的噪声}
7:    $\nabla_{\theta} ||\varepsilon_t - \varepsilon_{\theta t}||^2$  {使用梯度下降法调整  $\varepsilon_{\theta}$ }
8: until converged

```

算法 2 带条件 y 的逆向采样过程

输入: y

输出: x_0

```

 $x_T \leftarrow \mathcal{N}(0, I)$ 
2: for  $t = T, \dots, 1$  do
    $z \leftarrow \mathcal{N}(0, I)$ 
4:    $\varepsilon_{\theta t} \leftarrow \varepsilon_{\theta}(x_t, t, y)$  {使用网络模型预测添加的噪声}
    $x_{t-1} = \frac{1}{\sqrt{\alpha_t}}(x_t - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}}\varepsilon_{\theta t}) + \sigma_t z$  {获取上一步的图片  $x_{t-1}$ }
6: end for
   return  $x_0$ 

```

5.2.3 逆向去离焦过程

噪声预测网络 θ 在正向过程中得到训练，能够预测出任意 t 步添加到图片当中的噪声。将正向加噪声的过程逆转，逐步对有噪声的图片 x_t 进行去噪即为扩散模型的逆向过程。当输入一个离焦图片 y ，从随机采样的一个高斯分布噪声 (x_T) 开始，逐步预测每一步需要减去的噪声 $\varepsilon_\theta(x_t, t, y)$ ，并从 x_t 中减去预测的噪声，获得减少噪声过后的 x_{t-1} ，重复该步骤 T 次，即可预测出与离焦图片 y 所对应的清晰图片 x_0 ，实现对图片的去离焦。其过程如算法 2 所示。

5.3 实验结果与分析

5.3.1 离焦的融合

本章的核心研究内容聚焦于对由投影仪离焦引起的散斑退化进行重构。因此，为了进行训练和测试，本章采用了数据集 $Data_f$ ，其中包含不同程度散斑离焦的数据。值得一提的是，本章并没有直接使用 $Data_f$ 中的图像进行训练，而是经过多帧图像融合后再进行训练。在 $Data_f$ 中，每张离焦图像的所有像素位置的散斑离焦程度相同，然而在实际情况中，不同深度位置会产生不同程度的离焦。为了模拟真实情况，本文采用了多帧融合的方法。如图 5.3 和图 5.4。




图 5.3 聚焦最近处

Figure 5.3 Focus at the top point

具体而言，根据不同区域的视差值（深度），选择相应离焦程度图像，并将多帧散斑图像进行融合。本文模拟了两种不同的投影仪聚焦模式：一种是模拟物体最近点聚焦，远离投影仪的位置离焦程度更大；另一种是模拟物体中间深度聚焦，深度越近或越远离投影仪的位置离焦程度逐渐增加。本章共涉及 200 个模型，每个模型采用了上述两种融合方式，并且在生成单一离焦图像时，进行了 5 种不同位姿的摆放。每个模型还包括左右 2 个相机视角下的离焦和聚焦图像。因此，本章共有 4000 张融合离焦图像用于训练。




图 5.4 聚焦中间点处

Figure 5.4 Focus at the middle point

5.3.2 对比网络

本章选取了三个去离焦的网络进行去离焦效果的对比。这三个网络最初的都是基于单帧图像的相机拍摄到的图片的去模糊，但其整体效果与本章所研究内容相似，且目前没有直接研究对投影仪离焦时图像进行恢复的网络。因此选择了这三个网络：Ganv2^[56], IFAN^[61], DIDA^[62]。其中 GANv2 是比较经典的基于对抗式生成网络，且取得较好结果的去模糊网络，而 IFAN 是一种迭代滤波自适应网络，能够预测像素级去模糊过滤器，再进行迭代的离焦去除。DIDA 则是利用一个辅助网络来预估离焦图，再使用离焦图来指导图片进行去离焦，取得了目前最先进的去离焦效果。本文选择这三种方法进行比较检测本章提出方法的优越性。

5.3.3 参数设置与评价指标

在本章当中，使用上述所搭建的去离焦网络和离焦的数据集，在训练时使用的各项超参数为：学习率（learning rate）设置为 0.00002，批（batch size）大小设置为 3，扩散模型的预测步数设置为 988，训练图片的大小为 320 像素 × 320 像素。为了对去离焦过后的图片进行客观的离焦评价，本文选择了两个常用于图像去模糊的评价指标：峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）与结构相似性（Structural Similarity Index Measure, SSIM）。它们的计算方式分别如公式（5-2），（5-4）所示，使用这两个评价指标可以评估去离焦过后的图片与真实未离焦图片的相似程度。当它们的值变大时，表示去离焦过后的图片与真实图片越接近，网络的去离焦效果也就越好。峰值信噪比的计算公式（5-2）中 MAX_I^2 代表图像中像素可以取到的最大值，本章所使用的是归一化后的图片进行质量评估，因此这里是 1.0； MSE 表示的是两张图片 x 与 y 的均方误差，其计算方式如公式（5-3）所示。而 SSIM 主要从图片的亮度（luminance）、对比度（contrast）、结构（structure）三个特征来确定两张图片的相似程度，分别表示为公式（5-4）中的 $l(x, y)$ 、

$c(x, y)$ 、 $c(x, y)$ ，它们各自的计算公式表示为 (5-5)、(5-6)、(5-7)。其中的 $\mu = \frac{1}{N} \sum_{i=1}^N x_i$ 、 $\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \mu)^2}$ 分别代表图片的均值与标准差。而 σ_{xy} 为图片 x, y 之间的协方差，其计算方式如公式 (5-8) 所示。当对图片的三个特征的权重 α, β, γ 都取为 1 时可将公式 (5-5) 到公式 (5-8) 带入公式 (5-4) 中得到最终的计算公式 (5-9)。

$$PSNR = 10 \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \quad (5-2)$$

$$MSE = \frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (x(i, j), y(i, j)) \quad (5-3)$$

$$SSIM(x, y) = l(x, y)^\alpha \cdot c(x, y)^\beta \cdot s(x, y)^\gamma \quad (5-4)$$

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1} \quad (5-5)$$

$$c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2} \quad (5-6)$$

$$s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3} \quad (5-7)$$

$$\sigma_{xy} = \frac{1}{N-1} \sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y) \quad (5-8)$$

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (5-9)$$

5.3.4 去离焦实验

本章首先测试各个不同网络对于散斑的离焦恢复效果，针对第 5.3.1 小节中提到的两种不同融合方式获得的离焦散斑图片都进行了测试，图像重构结果如图 5.5 和图 5.6 所示。从图片整体来看各个方法都能够在一定程度上对离焦的散斑特征进行恢复。但从细节上来看，其他网络恢复的散斑特征都有一些扭曲，并不能完全恢复，特别在离焦较大的区域只有本文方法才能进行准确地恢复出散斑特征。从图中的局部放大可以看出本文方法能够更好更准确地恢复出散斑特征。本文将红色框内的部分进行裁剪，并对重建区域计算 PSNR 与 SSIM 并标注在下方，从评价指标也可以看出本文方法能够将离焦图片所丢失的信息进行恢复。为了进一步量化各个网络对于离焦区域的重建效果，本文统计了所有测试集上所得去离焦图片，并计算了它们的 PSNR 与 SSIM，其统计结果如表




图 5.5 最近点聚焦的去离焦结果对比

Figure 5.5 Deblurring result of top focus




图 5.6 中间聚焦的去离焦结果对比

Figure 5.6 Deblurring result of intermediate focus

5.1所示，从结构相似性来看，本文方法在整体上的散斑重构结果与 DIDA 同样属于最好的，在峰值信噪比上，本文方法是所有方法中最好的。

为了进一步探讨各个网络对于离焦区域的去离焦效果，本文对各种不同离焦程度的图片进行去离焦实验，统计各个网络在不同离焦程度时的峰值信噪比与结构相似性，并绘制成折线图如图5.7所示：从曲线结果可以看出，本文方法在离焦程度较低时效果并不比其他对比方法好，但是当离焦程度超过了 1.4mm 时从峰值信噪比与结构相似性两个指标来看都是本文方法最好，且随着离焦程度的提升，本文方法所受到的影响最小，评价指标的变化程度最小，证明该方法在离焦程度较大时具有更好的去离焦效果。同时

为了更加直观观察不同离焦程度的去离焦效果，本文使用各个网络对不同离焦程度的图片进行去离焦实验，并将去离焦结果绘制在图5.8中。从图中也可以看出，本文所提方法在各种不同的离焦程度上都能够进行散斑特征的重构，而其他网络在散斑离焦程度较大时就会出现散斑重构的错误，这对于后续的立体匹配来说是致命的。而考虑 DIDA 整体 SSIM 与本文所提方法相同的原因，DIDA 方法中有一个辅助任务为对离焦区域与离焦程度进行预测，当离焦程度较低时，可以减少对其的过多预测，不会引入新的噪声，因此在离焦程度较低时结果较好，从整体上计算结构相似性时 DIDA 与本文所提方法的 SSIM 相当。但是当离焦程度较大时本文方法可以进行明显更好的散斑重构。而 DIDA 与 IFAN 遇到离焦程度过大时通过模糊的散斑预测，会将局部的平均值与所需的像素均值相近，此策略虽然可以获得更高的评价指标，但是并不能真正较好地地进行图像的重建。

表 5.1 去离焦评价指标对比结果

Table 5.1 Comparison of defocus metrics

	GANv2	IFAN	DIDA	Ours
PSNR	26.585	28.254	30.676	31.132
SSIM	0.870	0.918	0.956	0.956




图 5.7 各离焦程度对比折线图

Figure 5.7 Plots of all defocus

5.3.5 三维重建实验

在本章当中，将去离焦网络与立体匹配网络 NMSCANet 构建双阶段网络可以实现对于离焦散斑的立体图像对进行视差求解。首先进行离焦散斑的重构然后使用重构的散斑进行立体匹配。本小节通过使用相同的立体匹配网络对不同的去离焦网络的去离焦图片进行匹配测试，对比不同去离焦网络去离焦的效果以及稳定性。本小节进行了两个实验，一个是对平面的重建，一个是对三维人脸的重建。




图 5.8 不同离焦程度的恢复结果

Figure 5.8 Deblur results of different defocus

5.3.5.1 平面重建实验

首先, 本小节对一个真实拍摄的离焦平面进行去离焦实验, 检测本方法是否适用于真实的离焦场景。利用第三章中搭建的双目采集系统对一个平面进行散斑的投射, 调整投影仪的焦距使投射到物体表面的散斑发生离焦, 将该离焦图像对送入去离焦网络与立体匹配网络获得视差图并进行三维重建, 并计算与未发生离焦时重建的点云的最近点距离与距离标准差。图5.9显示了离焦散斑图片与各个模型去离焦后的图片, 以及进行点云重建过后的点云误差图。并在点云误差图下标注了点云的最近点距离与距离的标准差。从图中的散斑重构图片来看, 本文方法重构的散斑具有更清晰的结构信息。进一步地, 使用重构的图片进行三维重建的点云误差更低。相较于发生离焦时, 本文方法重建点云的最近邻平均距离下降了 51.12%, 距离标准差下降了 47.42%。证明本章所提的方法具有较好去除真实散斑离焦模糊的效果。




图 5.9 真实平面检测结果

Figure 5.9 Result of real captured images

5.3.5.2 三维人脸重建实验

除了进行平面的三维重建，本文还进行了两种离焦融合方式下的人脸进行三维重建，检测本文所提方法进行去离焦后的图片能否用于后续的立体匹配网络。本文将各网络重构的散斑图片送入第四章中的立体匹配网络（NMSCANet）当中进行视差计算以及点云的重建。其中一对图像中的重构散斑图，立体匹配的视差图以及点云重建结果如图5.10所示。同时为了更加直观对比各种不同网络重构的散斑对于匹配网络的影响，本文在图中还标注了第四章所使用的视差以及点云的评价指标，进行更好地量化对比。根据图中的结果可以总结到，各种不同去模糊网络都能够对离焦的散斑进行重构，并提高立体匹配的精度。但当离焦程度过大时，只有本文所采用的去离焦算法能够更好地恢复散斑的特征，在立体匹配结果中拥有最小的端点误差与 0.5 像素误差。从可视化结果来看本章所提方法的点云建结果更加平滑，重建的点云与未发生离焦时重建的点云之间误差最低。进一步地，本文对于不同的去离焦网络在数据集 $Data_f$ 的两种融合方法上进行立体匹配与点云重建过后的评价指标统计如表5.2所示。从统计的平均结果也可以总结到，本章所提的方法在去离焦后进行相同的立体匹配拥有最低的视差端点误差与重建

表 5.2 立体匹配网络重建结果统计

Table 5.2 Statistical result of 3D reconstruction

	离焦	GANv2	IFAN	DIDA	Ours
EPE	1.5280	0.8510	0.3835	0.3765	0.2545
0.5PER (%)	10.86	5.66	3.79	4.04	2.42
MeanDis(mm)	0.9190	0.5215	0.2450	0.2265	0.1830
std	4.7230	3.4865	1.0050	0.8430	0.7745

点云的误差,相较于没有去离焦的立体匹配,EPE降低了83%,0.5像素误差降低了77%,重建点云的最近邻距离降低了80%,点云重建误差(Std)降低83%,进一步证明本章所提方法可以适用于基于散斑投射的立体匹配算法当中。另外,本文在没有进行融合的各个不同离焦程度上进行了三维重建的实验,其可视化结果如图5.11所示。根据可视化的结果,在各个不同的离焦程度下,本文方法都能够进行较好的去离焦并重建出完整的三维人脸,但是随着离焦程度的逐渐增大,图像中的散斑信息逐渐减少,散斑恢复难度越来越大,逐渐会引入噪声到重建的去离焦图像当中,匹配的精度也有所下降。但整体上本文方法仍然能够完成散斑的重建以及用于立体匹配重建出三维物体。




图 5.10 去离焦三维重建结果

Figure 5.10 Reconstruction of deblurred defocus pics




图 5.11 不同离焦程度的三维重建结果

Figure 5.11 reconstruction result of different defocus ratio

5.4 本章小结

在基于散斑投影与立体匹配的三维重建系统当中，当被测物体与投影仪之间的距离发生改变，或是物体深度跨度超越了投影仪的成像范围，都会导致散斑的模糊，最终影响立体匹配的精度。本章提出从图像生成的角度，利用条件扩散模型，使用离焦的图片作为图像生成的条件，“指导”噪声预测网络预测与去除离焦图片当中的离焦模糊，最终恢复出清晰的散斑图案。本章当中使用残差连接块与多尺度空间通道注意力构建了 UNet 型的基于扩散模型的去模糊网络，与现有的去模糊网络相比能够进行更好的散斑

特征恢复。同时本章还将去离焦的后的图片输入立体匹配网络，构建双阶段立体匹配网络，检验了本章所提的去离焦网络能够较好地进行去离焦并实现对于离焦散斑图案的高精度立体匹配。

第6章 结论与展望

6.1 本文工作总结

立体匹配是基于双目立体视觉三维重建技术的核心。通过对左右视图寻找同名点计算视差即可实现计算机对于三维世界深度的感知。在立体匹配的基础上,向被测物体投射散斑、条纹等结构光即可实现对无纹理或者弱纹理的物体进行三维重建。目前随着深度学习技术的快速发展,基于深度学习的立体匹配算法能够更快更高精度的进行匹配。但是基于深度学习这一数据驱动的匹配算法也会受到很多限制。例如在基于散斑投影的立体匹配算法当中,重建物体的距离通常会受到限制,当被测物体在测量系统中的深度发生变化时,投射到物体表面的散斑特征会发生尺寸的变化与图像的模糊,此时左右相机拍摄到的散斑特征与训练时的散斑特征发生变化,基于深度学习的匹配算法就容易导致匹配错误与匹配精度的下降。本文通过深度学习网络架构的探索,主要研究与解决的问题如下:

(1) 针对基于深度学习的方法中训练数据难以获取的问题,本文通过数字孪生技术构建与真实系统相似的仿真采集系统。在仿真系统内实现对数据的快速精准的采集。同时使用该仿真系统还可以进行量化研究在散斑立体匹配中散斑尺寸变化与散斑模糊给立体匹配网络带来的影响。

(2) 针对散斑尺寸变化导致立体匹配精度下降的问题,本文提出了归一化多尺度空间通道注意力模块,并将模块应用于特征提取当中,融合拼接代价体与相关性代价体的优势,构建 NMSCANet。实现于各种不同尺寸散斑特征的感知能力,以及网络对于散斑特征的传递与处理能力,保证散斑特征的完整性。最终的实验结果表明,本文所提的方法能够很好的减弱散斑尺寸变化给立体匹配网络带来的影响,使网络在一种散斑尺寸的训练下也能够实现对多种散斑特征的识别,提高了网络在不同的散斑尺寸下的匹配精度。

(3) 针对散斑模糊的问题,本文提出了使用条件扩散模型对模糊的图像进行恢复以及采用双阶段网络来实现三维重建的方法。由于图像模糊的重建是一个病态的问题,传统基于图像的算法很难进行完美的图像恢复。本文从图像生成的角度出发,利用扩散模型的强大生成能力,将图像去模糊视为去噪过程,通过多步的噪声预测与去除,最终实现对于模糊的去除,恢复散斑特征。最终的实验表明,本文所提的去模糊网络能够较好地对散斑图案进行恢复,同时该去模糊网络与立体匹配网络构建双阶段的网络即可实现对于模糊散斑情况下的立体匹配。

6.2 未来工作展望

本文针对基于散斑投影的立体匹配算法进行研究并减弱了散斑尺寸变化与散斑离焦带来的匹配精度下降问题，但是一个鲁棒的散斑立体匹配算法还有很多问题需要更进一步的研究：

（1）加快基于扩散模型的去离焦网络。目前的扩散模型去离焦需要经过多次的噪声预测最终实现去离焦，限制了该网络在实时三维重建当中的应用。可以考虑改变扩散模型的采样步长，提高去离焦的效率。

（2）提高相机摆放位置鲁棒性。现阶段的基于双目立体视觉技术的三维重建技术都需要保持左右相机摆放距离与角度不变才能够实现精准的立体匹配，给算法扩展应用硬件造成阻碍，可以考虑引入自回归匹配算法的思想，提高对于相机摆放位置的鲁棒性。

（3）提高匹配算法对光照鲁棒性。当有较强的环境光时容易导致左右视图对比度下降图像噪声增多，最终导致匹配精度的下降，可以考虑引入图像增强模块对图像进行预处理，在图像上对散斑特征进行恢复，再进行立体匹配。

参考文献

- [1] 魏加立, 曲慧东, 王永宪, 等. 基于飞行时间法的 3D 相机研究综述[J]. 红外技术, 2021, 43(01): 60-67.
- [2] MOULON P, MONASSE P, MARLET R. Adaptive structure from motion with a contrario model estimation[C]//Computer Vision-ACCV 2012: 11th Asian Conference on Computer Vision, Daejeon, Korea, November 5-9, 2012, Revised Selected Papers, Part IV 11. Springer, 2013: 257-270.
- [3] SCHONBERGER J L, FRAHM J M. Structure-from-motion revisited[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 4104-4113.
- [4] COLLET A, CHUANG M, SWEENEY P, et al. High-quality streamable free-viewpoint video[J]. ACM Transactions on Graphics (ToG), 2015, 34(4):1-13.
- [5] ZHENG Y, SHAO R, ZHANG Y, et al. Deepmulticap: Performance capture of multiple characters using sparse multiview cameras[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 6239-6249.
- [6] SHAO R, ZHENG Z, ZHANG H, et al. Diffustereo: High quality human reconstruction via diffusion-based stereo using sparse cameras[C]//European Conference on Computer Vision. Springer, 2022: 702-720.
- [7] SWEENEY C. Structure from motion (sfm)[EB/OL]. 2016. <http://theia-sfm.org/sfm.html#chapter-sfm>, Last accessed on 2024-4-10.
- [8] ZHANG Z. Review of single-shot 3d shape measurement by phase calculation-based fringe projection techniques[J]. Optics and lasers in engineering, 2012, 50(8):1097-1106.
- [9] ZUO C, FENG S, HUANG L, et al. Phase shifting algorithms for fringe projection profilometry: A review[J]. Optics and lasers in engineering, 2018, 109:23-59.
- [10] 王景隆, 曹益平, 李城梦, 等. 一种具有宽松约束的相位—高度映射算法[J]. 哈尔滨工业大学学报, 2020, 52(05):58-65.
- [11] FENG S, CHEN Q, GU G, et al. Fringe pattern analysis using deep learning[J]. Advanced Photonics, 2019, 1(2):025001-025001.
- [12] NGUYEN A H, REES O, WANG Z. Learning-based 3d imaging from single structured-light image[J]. Graphical Models, 2023, 126:101171.
- [13] WANG C, ZHOU P, ZHU J. Deep learning-based end-to-end 3d depth recovery from a single-frame fringe pattern with the msunet++ network[J]. Optics Express, 2023, 31(20):33287-33298.
- [14] 陈炎, 杨丽丽, 王振鹏. 双目视觉的匹配算法综述[J]. 图学学报, 2020, 41(05):702-708.
- [15] MEI X, SUN X, ZHOU M, et al. On building an accurate stereo matching system on graphics hardware [C]//2011 IEEE International Conference on Computer Vision Workshops (ICCV Workshops). IEEE, 2011: 467-474.
- [16] HAMZAH R A, IBRAHIM H, HASSAN A H A. Stereo matching algorithm based on per pixel difference adjustment, iterative guided filter and graph segmentation[J]. Journal of Visual Communication and Image Representation, 2017, 42:145-160.
- [17] HONG P N, AHN C W. Robust matching cost function based on evolutionary approach[J]. Expert Systems with Applications, 2020, 161:113712.

- [18] ZABIH R, WOODFILL J. Non-parametric local transforms for computing visual correspondence[C]// Computer Vision—ECCV'94: Third European Conference on Computer Vision Stockholm, Sweden, May 2–6 1994 Proceedings, Volume II 3. Springer, 1994: 151-158.
- [19] BANKS J, BENNAMOUN M. Reliability analysis of the rank transform for stereo matching[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2001, 31(6):870-880.
- [20] BLEYER M, RHEMANN C, ROTHER C. Patchmatch stereo-stereo matching with slanted support windows.[C]//Bmvc: volume 11. 2011: 1-11.
- [21] YANG Q. Stereo matching using tree filtering[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 37(4):834-846.
- [22] 戈豪豪. 基于树结构的立体匹配算法研究[D]. 杭州电子科技大学, 2018.
- [23] 何高奇, 杨宇, 倪佳, 等. 基于动态规划的实时立体匹配算法[J]. 华东理工大学学报(自然科学版), 2013(5):601-609.
- [24] 罗嗣卿, 贾子书. 基于动态规划快速立体匹配算法[J]. 计算机工程, 2015, 41(11):224-231.
- [25] LI K, WANG S, YUAN M, et al. Scale invariant control points based stereo matching for dynamic programming[C]//2009 9th International Conference on Electronic Measurement & Instruments. IEEE, 2009: 3-769.
- [26] HU T, QI B, WU T, et al. Stereo matching using weighted dynamic programming on a single-direction four-connected tree[J]. Computer Vision and Image Understanding, 2012, 116(8):908-921.
- [27] SUN J, ZHENG N N, SHUM H Y. Stereo matching using belief propagation[J]. IEEE Transactions on pattern analysis and machine intelligence, 2003, 25(7):787-800.
- [28] AHMADZADEH A, MADANI H, JAFARI K, et al. Fast and adaptive bp-based multi-core implementation for stereo matching[C]//2013 Eleventh ACM/IEEE International Conference on Formal Methods and Models for Codesign (MEMOCODE 2013). IEEE, 2013: 135-138.
- [29] DENG Y, YANG Q, LIN X, et al. A symmetric patch-based correspondence model for occlusion handling[C]//Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1: volume 2. IEEE, 2005: 1316-1322.
- [30] 刘忠艳, 周波, 张兴华, 等. 一种基于置信度传播的立体匹配算法[J]. 自动化与仪器仪表, 2010(01): 111-113.
- [31] ŽBONTAR J, LECUN Y. Stereo matching by training a convolutional neural network to compare image patches[J]. Journal of Machine Learning Research, 2016, 17(65):1-32.
- [32] MAYER N, ILG E, HÄUSSER P, et al. A large dataset to train convolutional networks for disparity, optical flow, and scene flow estimation[J/OL]. Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2016:4040-4048. DOI: 10.1109/CVPR.2016.438.
- [33] YANG G, ZHAO H, SHI J, et al. Segstereo: Exploiting semantic information for disparity estimation [C]//Proceedings of the European conference on computer vision (ECCV). 2018: 636-651.
- [34] KENDALL A, MARTIROSYAN H, DASGUPTA S, et al. End-to-end learning of geometry and context for deep stereo regression[J/OL]. Proceedings of IEEE International Conference on Computer Vision, 2017:66-75. DOI: 10.1109/ICCV.2017.17.
- [35] CHANG J R, CHEN Y S. Pyramid stereo matching network[J]. Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:5410-5418.
- [36] KANG J, CHEN L, DENG F, et al. Context pyramidal network for stereo matching regularized by

- disparity gradients[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2019, 157:201-215.
- [37] NGUYEN T P, JEON J W. Wide context learning network for stereo matching[J]. Signal Processing: Image Communication, 2019, 78:263-273.
- [38] 张伟, 黄娟, 顾寄南, 等. 基于联合注意力-可分离卷积的立体匹配算法[J]. 科学技术与工程, 2023, 23(31):13457-13463.
- [39] GUO X, YANG K, YANG W, et al. Group-wise correlation stereo network[J]. Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:3268-3277.
- [40] XU G, CHENG J, GUO P, et al. Attention concatenation volume for accurate and efficient stereo matching[J]. Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 12971-12980.
- [41] 党宏社, 许怀彪, 张选德. 融合结构信息的深度学习立体匹配算法[J]. 图学学报, 2023, 44(05): 899-906.
- [42] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [43] LI Y, LUO F, XIAO C. Self-supervised coarse-to-fine monocular depth estimation using a lightweight attention module[J]. Computational Visual Media, 2022, 8(4):631-647.
- [44] XU Y, YANG X, YU Y, et al. Depth estimation by combining binocular stereo and monocular structured-light[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 1746-1755.
- [45] ZHOU P, ZHU J, JING H. Optical 3-d surface reconstruction with color binary speckle pattern encoding [J]. Optics express, 2018, 26(3):3452-3465.
- [46] GUO J, GU F, YE Y, et al. An accurate speckle 3d reconstruction system based on binocular endoscope [C]//2021 IEEE International Conference on Real-time Computing and Robotics (RCAR). IEEE, 2021: 703-708.
- [47] YIN W, HU Y, FENG S, et al. Single-shot 3d shape measurement using an end-to-end stereo matching network for speckle projection profilometry[J]. Optics Express, 2021, 29(9):13388-13407.
- [48] WANG R, ZHOU P, ZHU J. Accurate 3d reconstruction of single-frame speckle-encoded textureless surfaces based on densely connected stereo matching network[J]. Optics Express, 2023, 31(9):14048-14067.
- [49] ZHOU P, FENG X, LUO J, et al. Temporal-spatial binary encoding method based on dynamic threshold optimization for 3d shape measurement[J]. Optics Express, 2023, 31(14):23274-23293.
- [50] ZHU J, LUO J, DU J, et al. Spatial - temporal binarization method via jointly optimizing diffusion kernel and quantization threshold for 3-d surface imaging[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73:1-13.
- [51] CAI B, LIU L, WU J, et al. Three-dimensional shape measurement based on spatial-temporal binary-coding method[J]. Measurement Science and Technology, 2021, 32(9):095014.
- [52] DONG J, PAN J, SUN D, et al. Learning data terms for non-blind deblurring[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 748-763.
- [53] NAN Y, JI H. Deep learning for handling kernel/model uncertainty in image deconvolution[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 2388-2397.

- [54] FANG Y, ZHANG H, WONG H S, et al. A robust non-blind deblurring method using deep denoiser prior[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 735-744.
- [55] FEI X, ZHAO J, ZHAO H, et al. Deblurring adaptive optics retinal images using deep convolutional neural networks[J]. Biomedical optics express, 2017, 8(12):5675-5687.
- [56] KUPYN O, MARTYNIUK T, WU J, et al. Deblurgan-v2: Deblurring (orders-of-magnitude) faster and better[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 8878-8887.
- [57] ZHAO W, WEI F, HE Y, et al. United defocus blur detection and deblurring via adversarial promoting learning[C]//European Conference on Computer Vision. Springer, 2022: 569-586.
- [58] ABUOLAIM A, BROWN M S. Defocus deblurring using dual-pixel data[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part X 16. Springer, 2020: 111-126.
- [59] ABUOLAIM A, AFIFI M, BROWN M S. Improving single-image defocus deblurring: How dual-pixel images help through multi-task learning[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2022: 1231-1239.
- [60] QUAN Y, WU Z, JI H. Gaussian kernel mixture network for single image defocus deblurring[J]. Advances in Neural Information Processing Systems, 2021, 34:20812-20824.
- [61] LEE J, SON H, RIM J, et al. Iterative filter adaptive network for single image defocus deblurring[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 2034-2042.
- [62] MA H, LIU S, LIAO Q, et al. Defocus image deblurring network with defocus map estimation as auxiliary task[J]. IEEE Transactions on Image Processing, 2021, 31:216-226.
- [63] ZAMIR S W, ARORA A, KHAN S, et al. Restormer: Efficient transformer for high-resolution image restoration[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5728-5739.
- [64] RUAN L, BEMANA M, SEIDEL H P, et al. Revisiting image deblurring with an efficient convnet[J]. arXiv preprint arXiv:2302.02234, 2023.
- [65] JOGLEKAR J, GEDAM S S, MOHAN B K. Image matching using sift features and relaxation labeling technique—a constraint initializing method for dense stereo matching[J]. IEEE Transactions on Geoscience and Remote Sensing, 2014, 52(9):5643-5652.
- [66] ZHOU Y, SONG Y, LU J. Stereo image dense matching by integrating sift and sgm algorithm[J]. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2018, 42:2565-2570.
- [67] SAYGILI G, VAN DER MAATEN L, HENDRIKS E A. Improving segment based stereo matching using surf key points[C]//2012 19th IEEE International Conference on Image Processing. IEEE, 2012: 2973-2976.
- [68] LI X, LUO X, WU Y, et al. Research on stereo matching for satellite generalized image pair based on improved surf and rfm[C]//IGARSS 2020-2020 IEEE International Geoscience and Remote Sensing Symposium. IEEE, 2020: 2739-2742.
- [69] YU C, JI F, XUE J, et al. Adaptive binocular fringe dynamic projection method for high dynamic range

- measurement[J]. *Sensors*, 2019, 19(18).
- [70] YIN W, FENG S, TAO T, et al. High-speed 3d shape measurement using the optimized composite fringe patterns and stereo-assisted structured light system[J]. *Optics Express*, 2019, 27:2411.
- [71] ZUO C, TAO T, FENG S, et al. Micro fourier transform profilometry (uftp): 3d shape measurement at 10,000 frames per second[J]. *Optics and Lasers in Engineering*, 2018, 102:70-91.
- [72] 当贝投影. 什么是 DLP 投影技术[EB/OL]. 2019. <https://zhuanlan.zhihu.com/p/85548707>.
- [73] ZHANG Z, WANG X, JUNG C. Dcsr: Dilated convolutions for single image super-resolution[J]. *IEEE Transactions on Image Processing*, 2019:1625-1635.
- [74] CHEN J, WAN L, ZHU J, et al. Multi-scale spatial and channel-wise attention for improving object detection in remote sensing imagery[J]. *IEEE Geoscience and Remote Sensing Letters*, 2020:681-685.
- [75] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018: 7132-7141.
- [76] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[J]. *Proceedings of Computer Vision*, 2018, 11211:3-19.
- [77] DHARIWAL P, NICHOL A. Diffusion models beat gans on image synthesis[J]. *Advances in neural information processing systems*, 2021, 34:8780-8794.
- [78] WANG F, WANG C, GUAN Q. Single-shot fringe projection profilometry based on deep learning and computer graphics[J]. *Optics Express*, 2021:8024.
- [79] GEIGER A, LENZ P, STILLER C, et al. Vision meets robotics: The kitti dataset[J]. *The International Journal of Robotics Research*, 2013:1231-1237.
- [80] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//*2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016: 770-778.